МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №1

по дисциплине «Основы машинного обучения»

Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Выполнил:
студент 2 курса
группы АС-67
Иванович Д. И.

Проверил:
Крощенко А. А.

2026

Цель: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации.
Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

Задания по вариантам:

Вариант 3

Выборка Iris. Классический набор данных для классификации, содержащий измерения длины и ширины чашелистиков и лепестков для трех видов ирисов.

1. Загрузите данные и проверьте, есть ли в них пропущенные значения.

```
Первые 5 строк данных:
   sepal.length  sepal.width  petal.length  petal.width variety
0           5.1          3.5           1.4          0.2  Setosa
1           4.9          3.0           1.4          0.2  Setosa
2           4.7          3.2           1.3          0.2  Setosa
3           4.6          3.1           1.5          0.2  Setosa
4           5.0          3.6           1.4          0.2  Setosa

Размер набора данных:
(150, 5)

Количество пропущенных значений:
sepal.length    0
sepal.width     0
petal.length    0
petal.width     0
variety         0
dtype: int64
Пропущенных значений нет.
```

2. Выведите количество образцов каждого вида ириса.

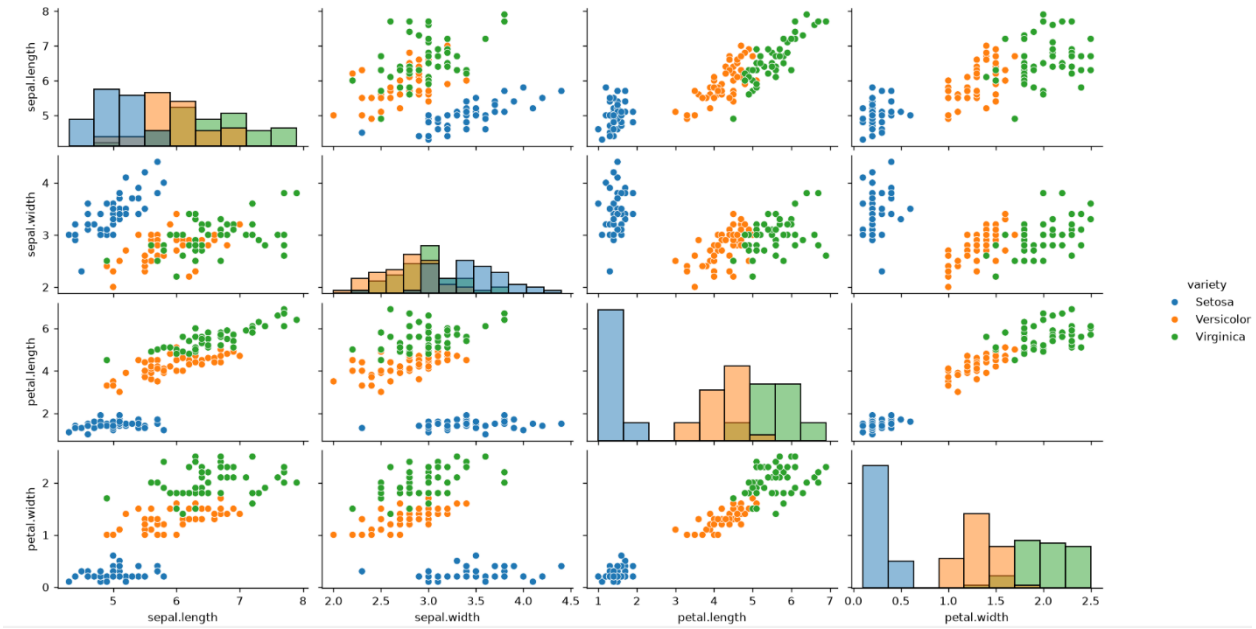
```
Количество образцов каждого вида ириса:
variety
Setosa        50
Versicolor    50
Virginica     50
Name: count, dtype: int64
```

3. Постройте парные диаграммы рассеяния (pair plot) для всех признаков, чтобы визуально оценить их разделимость.

4. Для каждого вида ириса рассчитайте среднее значение по каждому из четырех признаков.

```
Средние значения признаков для каждого вида ириса:
            sepal.length  sepal.width  petal.length  petal.width
variety
Setosa              5.01         3.43          1.46         0.25
Versicolor          5.94         2.77          4.26         1.33
Virginica           6.59         2.97          5.55         2.03
```

5. Создайте "ящик с усами" (box plot) для признака Petal Length (cm), чтобы сравнить его распределение по разным видам ирисов.



6. Стандартизируйте данные (приведите к нулевому среднему и единичному стандартному отклонению).

```
Первые 5 строк стандартизированных данных:
   sepal.length  sepal.width  petal.length  petal.width variety
0        -0.901        1.019        -1.340       -1.315  Setosa
1        -1.143       -0.132        -1.340       -1.315  Setosa
2        -1.385        0.328        -1.397       -1.315  Setosa
3        -1.507        0.098        -1.283       -1.315  Setosa
4        -1.022        1.249        -1.340       -1.315  Setosa

Средние значения после стандартизации:
sepal.length   -0.0
sepal.width    -0.0
petal.length   -0.0
petal.width    -0.0
dtype: float64

Стандартные отклонения после стандартизации:
sepal.length    1.0
sepal.width     1.0
petal.length    1.0
petal.width     1.0
dtype: float64

Стандартизированные данные сохранены в iris_standardized.csv
```

Код:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler

# 1. Загрузка данных и проверка пропущенных значений
df = pd.read_csv("iris.csv")

print("Первые 5 строк данных:")
print(df.head())

print("\nРазмер набора данных:")
print(df.shape)

print("\nКоличество пропущенных значений:")
print(df.isnull().sum())

if df.isnull().sum().sum() == 0:
    print("Пропущенных значений нет.")
else:
    print("В данных есть пропущенные значения.")

# Названия признаков и столбец с видами ирисов
features = [
    "sepal.length",
    "sepal.width",
    "petal.length",
    "petal.width"
]
target = "variety"

# 2. Количество образцов каждого вида ириса
print("\nКоличество образцов каждого вида ириса:")
print(df[target].value_counts())

# 3. Парные диаграммы рассеяния (Pair Plot)
sns.pairplot(
    df,
    vars=features,
    hue=target,
```

```
    diag_kind="hist"
)

plt.suptitle("Парные диаграммы рассеяния для Iris", y=1.02)
plt.show()

# 4. Среднее значение каждого признака для каждого вида ириса
means = df.groupby(target)[features].mean()

print("\nСредние значения признаков для каждого вида ириса:")
print(means.round(2))

# 5. Ящик с усами для Petal Length
plt.figure(figsize=(8, 5))

sns.boxplot(
    data=df,
    x=target,
    y="petal.length"
)

plt.title("Распределение длины лепестка по видам ирисов")
plt.xlabel("Вид ириса")
plt.ylabel("Petal Length (cm)")
plt.grid(axis="y", linestyle="--", alpha=0.5)
plt.tight_layout()
plt.show()

# 6. Стандартизация признаков
scaler = StandardScaler()

df_scaled = df.copy()
df_scaled[features] = scaler.fit_transform(df[features])

print("\nПервые 5 строк стандартизированных данных:")
print(df_scaled.head().round(3))

print("\nСредние значения после стандартизации:")
print(df_scaled[features].mean().round(3))

print("\nСтандартные отклонения после стандартизации:")
print(df_scaled[features].std(ddof=0).round(3))

# Сохранение стандартизированных данных в отдельный файл
df_scaled.to_csv("iris_standardized.csv", index=False)

print("\nСтандартизированные данные сохранены в iris_standardized.csv")
```

Вывод: Я познакомился с Pandas и Matplotlib и научился их применять для анализа данных.