

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Вариант 4

По дисциплине «Основы машинного обучения»

Тема: **«Знакомство с анализом данных: предварительная обработка и визуализация»**

Выполнил:

Студенты 3 курса

Группы АС-67

Кирик А. Д.

Проверил:

Крощенко А. А.

Брест 2026

Цель работы: Получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Задание 1.

Выборка Wine Quality. Содержит физико-химические показатели красного и белого вина и оценку его качества по шкале.

Задачи:

1. Загрузите данные и выведите информацию о типах столбцов.
2. Преобразуйте целевую переменную quality в категориальную: "плохое" (≤ 4), "среднее" (5-6), "хорошее" (≥ 7).
3. Постройте столбчатую диаграмму, показывающую количество вин каждой новой категории качества.
4. Проверьте корреляцию между fixed acidity и pH. Визуализируйте эту зависимость на диаграмме рассеяния.
5. Найдите признак с наибольшим количеством выбросов, используя "ящик с усами" (box plot).
6. Выполните стандартизацию всех числовых признаков.

Код программы:

```
import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt

def find_max_fliers_column(df : pd.DataFrame) -> tuple[int, int]:
    fig, ax = plt.subplots()
    box_plot = ax.boxplot(
        df,
        tick_labels=df.columns.to_list()
    )
    outlier_counts : list[int] = [len(fliers.get_ydata()) for fliers in
box_plot['fliers']]
    fliers_max_column : int = int(np.argmax(outlier_counts))
    plt.close()
    return fliers_max_column, outlier_counts[fliers_max_column]

def main() -> None:
    try:
        # Таблица качества проб вина
        wine_quality : pd.DataFrame = pd.read_csv('winequality-white.csv',
sep=';')
        print(f"Типы данных столбцов:\n{wine_quality.dtypes}")

        # Промежутки, по которым распределяются данные
        qual_bins : list[int | float] = [-float('inf'), 4, 6, float('inf')]
        # Именования промежутков
        qual_labels : list[str] = ['плохое', 'среднее', 'хорошее']

        # Категоризация значений качества вина
```

```

wine_quality["quality"] = pd.cut(
    wine_quality["quality"],
    bins=qual_bins,
    labels=qual_labels,
    right=True,
    include_lowest=True
).astype('category')

# Вычисление коэффициента корреляции между 'fixed acidity' и 'pH'
(коэфф. Пирсона)
corr_value, p_value = stats.pearsonr(wine_quality['fixed acidity'],
wine_quality['pH'])
# Подсчет количества проб каждого типа качества
quantity_of_qualities : pd.Series = (wine_quality.groupby("quality")
["quality"].count())
"""Построение столбчатой диаграммы количества вин каждой категории
качества"""
np.random.seed(34)
colors : np.ndarray = np.random.uniform(15, 80,
len(wine_quality['fixed acidity']))
fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2)
fig.canvas.manager.set_window_title("Визуализация характеристик проб
вин") # type: ignore
ax1.bar(qual_labels,
    quantity_of_qualities.values,
    width=1,
    edgecolor="white",
    linewidth=0.7,
    )
ax1.set_title("Категории качества")

"""Построение графика корреляции fixed acidity и pH"""
ax2.scatter(x=wine_quality['fixed acidity'].values,
y=wine_quality['pH'].values, c=colors, s=50, vmin=1, vmax=75, alpha=0.5)
ax2.set(
    xlabel='Fixed acidity',
    ylabel='pH',
    title=f"Корреляция между 'fixed acidity' и 'pH'."
)
# Вычисление линии тренда
z : np.ndarray = np.polyfit(
    wine_quality['fixed acidity'],
    wine_quality['pH'],
    1
)
p = np.poly1d(z)
fixed_acidity_interpolation : pd.Series = (wine_quality.loc[
    wine_quality['fixed acidity'].between(
    wine_quality['fixed acidity'].quantile(.0025),
    wine_quality['fixed acidity'].quantile(.990)),
    'fixed acidity']
)
# График линии тренда
ax2.plot(fixed_acidity_interpolation.values,
    p(fixed_acidity_interpolation),
    c='red',
    linewidth=2,
    label=f"Тренд (k={corr_value:.2f})")
ax2.legend()
numeric_col : pd.DataFrame = (wine_quality.

```

```

select_dtypes(include='number')
)
# Нахождение колонки с максимальным количеством выбросов
max_fliers_column, count = find_max_fliers_column(numeric_col)
print(f"Величина '{wine_quality.columns[max_fliers_column]}' имеет
наибольшее количество выбросов: {count}")

plt.show()
# Стандартизация числовых значений
for col_name in numeric_col.columns.to_list():
    wine_quality[col_name] = (wine_quality[col_name] -
wine_quality[col_name].mean()) / wine_quality[col_name].std()
print(wine_quality)
except Exception as a:
    print(a)

if __name__ == "__main__":
    main()

```

Спецификация вывода:

Типы данных столбов: <таблица типов столбцов>

Величина <имя столбца> имеет наибольшее количество выбросов:
<количество выбросов>

<Таблица со стандартизированными значениями>

Изображения результатов работы программы:


```

Типы данных столбов:
fixed acidity      float64
volatile acidity   float64
citric acid        float64
residual sugar     float64
chlorides          float64
free sulfur dioxide float64
total sulfur dioxide float64
density            float64
pH                 float64
sulphates          float64
alcohol            float64
quality            int64
dtype: object
Величина 'citric acid' имеет наибольшее количество выбросов: 270

```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	0.172079	-0.081762	0.213258	2.821061	-0.035351	0.569873	0.744489	2.331274	-1.246794	-0.349149	-1.393010	среднее
1	-0.657434	0.215874	0.047996	-0.944669	0.147732	-1.252891	-0.149669	-0.089153	0.739953	0.001342	-0.824192	среднее
2	1.475600	0.017450	0.543783	0.100272	0.193503	-0.312109	-0.973236	0.358628	0.475053	-0.436771	-0.336633	среднее
3	0.409083	-0.478608	-0.117266	0.415726	0.559670	0.687471	1.120977	0.525802	0.011479	-0.787262	-0.499152	среднее
4	0.409083	-0.478608	-0.117266	0.415726	0.559670	0.687471	1.120977	0.525802	0.011479	-0.787262	-0.499152	среднее
...	...	...	...	...	...	...	...	...	...	...	...	...
4893	-0.775936	-0.677032	-0.365159	-0.944669	-0.309976	-0.664902	-1.090889	-0.965385	0.541278	0.088964	0.557225	среднее
4894	-0.301928	0.414297	0.213258	0.317146	0.056190	1.275460	0.697428	0.291759	-0.253420	-0.261526	-0.742932	среднее
4895	-0.420430	-0.379397	-1.191470	-1.023532	-0.218435	-0.312109	-0.643809	-0.497299	-1.313019	-0.261526	-0.905451	среднее
4896	-1.605449	0.116662	-0.282528	-1.043248	-1.088081	-0.900098	-0.667340	-1.784534	1.004853	-0.962507	1.857382	хорошее
4897	-1.012940	-0.677032	0.378521	-1.102396	-1.179623	-0.782500	-0.949706	-1.543805	0.475053	-1.488242	1.044784	среднее

[4898 rows x 12 columns]



Вывод: получил базовые навыки по работе с массивами данных с помощью библиотеки Pandas а также визуального представления с помощью Mathplotlib. Был найден коэффициент между параметрами '*fixed acidity*' и '*pH*' – -0.43. Это свидетельствует об обратной зависимости между этими показателями. Самой многочисленной категорией качества вин оказалось «среднее», а самой малочисленной – «плохое».