

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Вариант 4

По дисциплине «Основы машинного обучения»

Тема: **«Знакомство с анализом данных: предварительная обработка и визуализация»**

Выполнил:

Студенты 3 курса

Группы АС-67

Кирик А. Д.

Проверил:

Крощенко А. А.

Брест 2026

Цель работы: Получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Задание 1.

Выборка Wine Quality. Содержит физико-химические показатели красного и белого вина и оценку его качества по шкале.

Задачи:

1. Загрузите данные и выведите информацию о типах столбцов.
2. Преобразуйте целевую переменную quality в категориальную: "плохое" (≤ 4), "среднее" (5-6), "хорошее" (≥ 7).
3. Постройте столбчатую диаграмму, показывающую количество вин каждой новой категории качества.
4. Проверьте корреляцию между fixed acidity и pH. Визуализируйте эту зависимость на диаграмме рассеяния.
5. Найдите признак с наибольшим количеством выбросов, используя "ящик с усами" (box plot).
6. Выполните стандартизацию всех числовых признаков.

Код программы:

```
import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
from typing import Literal

def find_min_max_fliers_column(df : pd.DataFrame, mode : Literal['max', 'min']) ->
tuple[int, int]:
    fig, ax = plt.subplots()
    box_plot = ax.boxplot(
        df,
        tick_labels=df.columns.to_list()
    )
    outlier_counts : list[int] = [len(fliers.get_ydata()) for fliers in
box_plot['fliers']]
    fliers_column : int
    if mode == 'max':
        fliers_column : int = int(np.argmax(outlier_counts))
    elif mode == 'min':
        fliers_column : int = int(np.argmin(outlier_counts))

    plt.close()
    return fliers_column, outlier_counts[fliers_column]

def main() -> None:
```

```

try:
    # Таблица качества проб вина
    wine_quality : pd.DataFrame = pd.read_csv('winequality-white.csv', sep=';')
    print(f"Типы данных столбов:\n{wine_quality.dtypes}")

    # Промежутки, по которым распределяются данные
    qual_bins : list[int | float] = [-float('inf'), 4, 6, float('inf')]
    # Именования промежутков
    qual_labels : list[str] = ['плохое', 'среднее', 'хорошее']

    # Категоризация значений качества вина
    wine_quality["quality"] = pd.cut(
        wine_quality["quality"],
        bins=qual_bins,
        labels=qual_labels,
        right=True,
        include_lowest=True
    ).astype('category')

    # Вычисление коэффициента корреляции между 'fixed acidity' и 'pH' (коэфф.
    Пирсона)
    corr_value, p_value = stats.pearsonr(wine_quality['fixed acidity'],
    wine_quality['pH'])
    # Подсчет количества проб каждого типа качества
    quantity_of_qualities : pd.Series = (wine_quality.groupby("quality")
        ["quality"].count())

    """Построение столбчатой диаграммы количества вин каждой категории
    качества"""
    np.random.seed(34)
    colors : np.ndarray = np.random.uniform(15, 80, len(wine_quality['fixed
    acidity']))
    fig, (ax1, ax2, ax3) = plt.subplots(nrows=1, ncols=3)
    fig.canvas.manager.set_window_title("Визуализация характеристик проб вин") #
type: ignore
    ax1.bar(qual_labels,
        quantity_of_qualities.values,
        width=1,
        edgecolor="white",
        linewidth=0.7,
        )
    ax1.set_title("Категории качества")

    """Построение графика корреляции fixed acidity и pH"""
    ax2.scatter(x=wine_quality['fixed acidity'].values,
    y=wine_quality['pH'].values, c=colors, s=50, vmin=1, vmax=75, alpha=0.5)
    ax2.set(
        xlabel='Fixed acidity',
        ylabel='pH',
        title=f"Корреляция между 'fixed acidity' и 'pH'."
    )
    # Вычисление линии тренда

```

```

z : np.ndarray = np.polyfit(
    wine_quality['fixed acidity'],
    wine_quality['pH'],
    1
)
p = np.poly1d(z)
fixed_acidity_interpolation : pd.Series = (wine_quality.loc[
    wine_quality['fixed acidity'].between(
        wine_quality['fixed acidity'].quantile(.0025),
        wine_quality['fixed acidity'].quantile(.990)),
    'fixed acidity']
)
# График линии тренда
ax2.plot(fixed_acidity_interpolation.values,
        p(fixed_acidity_interpolation),
        c='red',
        linewidth=2,
        label=f"Тренд (k={corr_value:.2f})")
ax2.legend()
numeric_col : pd.DataFrame = (wine_quality.
                                select_dtypes(include='number')
)
# Нахождение колонки с максимальным количеством выбросов
max_fliers_column, count = find_min_max_fliers_column(numeric_col, 'max')
min_fliers_column, min_count = find_min_max_fliers_column(numeric_col, 'min')
max_flaiers_col_name : str = numeric_col.columns[max_fliers_column]
min_fliers_col_name : str = numeric_col.columns[min_fliers_column]
ax3.boxplot(pd.DataFrame({max_flaiers_col_name:
wine_quality[max_flaiers_col_name], min_fliers_col_name:
wine_quality[min_fliers_col_name]}))
ax3.set_title("Показатели с наименьшим и наибольшим количеством выбросов")
ax3.set_xticklabels([max_flaiers_col_name, min_fliers_col_name])
print(f"Величина '{max_flaiers_col_name}' имеет наибольшее количество
выбросов: {count}")
print(f"Величина '{min_fliers_col_name}' имеет наименьшее количество
выбросов: {min_count}")

plt.show()
# Стандартизация числовых значений
for col_name in numeric_col.columns.to_list():
    wine_quality[col_name] = (wine_quality[col_name] -
wine_quality[col_name].mean()) / wine_quality[col_name].std()
    print(wine_quality)
except Exception as a:
    print(a)

if __name__ == "__main__":
    main()

```

Спецификация вывода:

Типы данных столбцов: <таблица типов столбцов>

Величина <имя столбца> имеет наибольшее количество выбросов:
<количество выбросов>



<Таблица со стандартизированными значениями>

Изображения результатов работы программы:


```
citric acid          float64
residual sugar       float64
chlorides            float64
free sulfur dioxide  float64
total sulfur dioxide float64
density              float64
pH                   float64
sulphates            float64
alcohol              float64
quality              int64
dtype: object
Величина 'citric acid' имеет наибольшее количество выбросов: 270
Величина 'alcohol' имеет наименьшее количество выбросов: 0
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	0.172079	-0.081762	0.213258	2.821061	-0.035351	0.569873	0.744489	2.331274	-1.246794	-0.349149	-1.393010	среднее
1	-0.657434	0.215874	0.047996	-0.944669	0.147732	-1.252891	-0.149669	-0.009153	0.739953	0.001342	-0.824192	среднее
2	1.475600	0.017450	0.543783	0.100272	0.193503	-0.312109	-0.973236	0.358628	0.475053	-0.436771	-0.336633	среднее
3	0.409083	-0.478608	-0.117266	0.415726	0.559670	0.687471	1.120977	0.525802	0.011479	-0.787262	-0.499152	среднее
4	0.409083	-0.478608	-0.117266	0.415726	0.559670	0.687471	1.120977	0.525802	0.011479	-0.787262	-0.499152	среднее
...	...	...	...	...	...	...	...	...	...	...	...	...
4893	-0.775936	-0.677032	-0.365159	-0.944669	-0.309976	-0.664902	-1.090889	-0.965385	0.541278	0.088964	0.557225	среднее
4894	-0.301928	0.414297	0.213258	0.317146	0.056190	1.275460	0.697428	0.291759	-0.253420	-0.261526	-0.742932	среднее
4895	-0.420430	-0.379397	-1.191470	-1.023532	-0.218435	-0.312109	-0.643809	-0.497299	-1.313019	-0.261526	-0.905451	среднее
4896	-1.605449	0.116662	-0.282528	-1.043248	-1.088081	-0.900098	-0.667340	-1.784534	1.004853	-0.962507	1.857382	хорошее
4897	-1.012940	-0.677032	0.378521	-1.102396	-1.179623	-0.782500	-0.949706	-1.543805	0.475053	-1.488242	1.044784	среднее

[4898 rows x 12 columns]



Показатели с наименьшим и наибольшим количеством выбросов



Вывод: получил базовые навыки по работе с массивами данных с помощью библиотеки Pandas а также визуального представления с помощью Mathplotlib. Был найден коэффициент между параметрами '*fixed acidity*' и '*pH*' – -0.43. Это свидетельствует об обратной зависимости между этими показателями. Самой многочисленной категорией качества вин оказалось «среднее», а самой малочисленной – «плохое».