

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность АС-67

Выполнил
Б.В. Кошелев,
студент группы АС-67
Проверил
А. А. Крощенко, ст.
преп. кафедры ИИТ,
« ____ » _____ 2026 г.

Брест 2026

Цель работы: получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 6

Выборка Heart Disease. Содержит медицинские данные пациентов, такие как возраст, пол, уровень холестерина, и наличие заболевания сердца.

Задачи:

1. Загрузите данные и выведите информацию о них. Проверьте на наличие пропусков.
2. Постройте столбчатую диаграмму, сравнивающую количество здоровых и больных пациентов.
3. Создайте диаграмму рассеяния, показывающую зависимость максимального пульса (thalach) от возраста (age). Раскрасьте точки в зависимости от наличия болезни.
4. Преобразуйте признак sex (0 = женщина, 1 = мужчина) в более читаемый формат с категориями 'female' и 'male', а затем примените к нему One-Hot Encoding.
5. Рассчитайте средний уровень холестерина (chol) для больных и здоровых пациентов.
6. Выполните нормализацию признаков age, trestbps, chol и thalach.Выполнение:

Код программы:

```
import pandas as pd
import numpy as np
import matplotlib
matplotlib.use('TkAgg')
import matplotlib.pyplot as plt

plt.style.use('seaborn-v0_8')
pd.set_option('display.max_columns', None)

df = pd.read_csv(r'heart.csv')

print("1. ИНФОРМАЦИЯ О ДАТАСЕТЕ")
print("Размер датасета:", df.shape)
print("\nПервые 5 строк:")
print(df.head())
print("\nИнформация о датафрейме:")
df.info()
print("\nПропуски по столбцам:")
print(df.isnull().sum())
print("Всего пропусков:", df.isnull().sum().sum())
```

```

counts = df['target'].value_counts().sort_index()

plt.figure(figsize=(6, 4))
plt.bar(['Здоровые (0)', 'Больные (1)'], counts.values, color=['#2ecc71', '#e74c3c'])
plt.title('Количество здоровых и больных пациентов')
plt.xlabel('Состояние')
plt.ylabel('Количество пациентов')
for i, v in enumerate(counts.values):
    plt.text(i, v + 5, str(v), ha='center', fontsize=11)
plt.savefig('graph1_target.png', dpi=100)
plt.show()

print("\nЗдоровых:", counts[0], "| Больных:", counts[1])

plt.figure(figsize=(9, 6))
plt.scatter(df[df.target == 0]['age'], df[df.target == 0]['thalach'],
            c='#2ecc71', label='Здоровые', alpha=0.7, edgecolors='k')
plt.scatter(df[df.target == 1]['age'], df[df.target == 1]['thalach'],
            c='#e74c3c', label='Больные', alpha=0.7, edgecolors='k')
plt.title('Зависимость максимального пульса от возраста')
plt.xlabel('Возраст (age)')
plt.ylabel('Максимальный пульс (thalach)')
plt.legend()
plt.grid(alpha=0.3)
plt.savefig('graph2_scatter.png', dpi=100)
plt.show()

df['sex'] = df['sex'].map({0: 'female', 1: 'male'})
print("\nУникальные значения sex:", df['sex'].unique())

df = pd.get_dummies(df, columns=['sex'], drop_first=True)
print("Столбцы после One-Hot Encoding:")
print(df.columns.tolist())

mean_chol = df.groupby('target')['chol'].mean()
print("\nСредний холестерин:")
print(f"    Здоровые (0): {mean_chol[0]:.2f}")
print(f"    Больные   (1): {mean_chol[1]:.2f}")

plt.figure(figsize=(6, 4))
plt.bar(['Здоровые', 'Больные'], [mean_chol[0], mean_chol[1]],
        color=['#2ecc71', '#e74c3c'])
plt.title('Средний уровень холестерина')
plt.ylabel('chol')
plt.savefig('graph3_chol.png', dpi=100)
plt.show()

cols = ['age', 'trestbps', 'chol', 'thalach']

```

```

print("\nДО нормализации:")
print(df[cols].describe().loc[['min', 'max', 'mean']])

for col in cols:
    df[col] = (df[col] - df[col].min()) / (df[col].max() - df[col].min())

print("\nПОСЛЕ нормализации:")
print(df[cols].describe().loc[['min', 'max', 'mean']])

print("\nГотово. Графики сохранены в файлы graph1_target.png, graph2_scatter.png,
graph3_chol.png")

```

Результат программы:

1. ИНФОРМАЦИЯ О ДАТАСЕТЕ

Размер датасета: (303, 14)

Первые 5 строк:

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope \
0	63	1	3	145	233	1	0	150	0	2.3	0
1	37	1	2	130	250	0	1	187	0	3.5	0
2	41	0	1	130	204	0	0	172	0	1.4	2
3	56	1	1	120	236	0	1	178	0	0.8	2
4	57	0	0	120	354	0	1	163	1	0.6	2

	ca	thal	target
0	0	1	1
1	0	2	1
2	0	2	1
3	0	2	1
4	0	2	1

Информация о датафрейме:

<class 'pandas.DataFrame'>

RangeIndex: 303 entries, 0 to 302

Data columns (total 14 columns):

Column Non-Null Count Dtype

```

---
0 age      303 non-null  int64
1 sex      303 non-null  int64
2 cp       303 non-null  int64
3 trestbps 303 non-null  int64
4 chol     303 non-null  int64
5 fbs      303 non-null  int64
6 restecg  303 non-null  int64
7 thalach  303 non-null  int64
8 exang    303 non-null  int64
9 oldpeak  303 non-null  float64
10 slope   303 non-null  int64
11 ca      303 non-null  int64

```

```
12 thal    303 non-null  int64
13 target  303 non-null  int64
dtypes: float64(1), int64(13)
memory usage: 33.3 KB
```

Пропуски по столбцам:

```
age      0
sex      0
cp       0
trestbps 0
chol     0
fbs      0
restecg  0
thalach  0
exang    0
oldpeak  0
slope    0
ca       0
thal     0
target   0
dtype: int64
```

Всего пропусков: 0

Здоровых: 138 | Больных: 165

Уникальные значения sex: <StringArray>

```
['male', 'female']
```

Length: 2, dtype: str

Столбцы после One-Hot Encoding:

```
['age', 'cp', 'trestbps', 'chol', 'fbs', 'restecg', 'thalach', 'exang', 'oldpeak', 'slope', 'ca', 'thal', 'target', 'sex_male']
```

Средний холестерин:

Здоровые (0): 251.09

Больные (1): 242.23

ДО нормализации:

```
      age  trestbps    chol  thalach
min 29.000000  94.000000 126.000000  71.000000
max 77.000000 200.000000 564.000000 202.000000
mean 54.366337 131.623762 246.264026 149.646865
```

ПОСЛЕ нормализации:

```
      age  trestbps    chol  thalach
min 0.000000 0.000000 0.000000 0.000000
max 1.000000 1.000000 1.000000 1.000000
mean 0.528465 0.354941 0.274575 0.600358
```

Готово. Графики сохранены в файлы graph1_target.png, graph2_scatter.png, graph3_chol.png



