МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность АС-67

Выполнил
Д. А. Ерш,
студент группы АС-67

Проверил
А. А. Крощенко,
ст. преп. кафедры ИИТ,
«___> _____2026 г.

Брест 2026

Цель работы: получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных,такие как очистка, нормализация и работа с различными типами признаков.

Вариант 4

Выборка Wine Quality. Содержит физико-химические показатели красного и белого вина и оценку его качества по шкале.

Задачи:

1. Загрузите данные и выведите информацию о типах столбцов.
2. Преобразуйте целевую переменную quality в категориальную: "плохое" (<=4), "среднее" (5-6), "хорошее" (>=7).
3. Постройте столбчатую диаграмму, показывающую количество вин каждой новой категории качества.
4. Проверьте корреляцию между fixed acidity и pH. Визуализируйте эту зависимость на диаграмме рассеяния.
5. Найдите признак с наибольшим количеством выбросов, используя "ящик с усами" (box plot).
6. Выполните стандартизацию всех числовых признаков.

Выполнение:

Код программы:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from pathlib import Path

folder = Path(__file__).resolve().parent
df = pd.read_csv(folder / "winequality-white.csv", sep=";")

pd.set_option("display.max_columns", None)
pd.set_option("display.width", 1500)

print("Первые 5 строк:")
print(df.head().to_string(index=False))

print("\n1. Информация о типах столбцов:")
df.info()

print("\nКоличество пропусков:")
print(df.isnull().sum())

numeric_columns = df.select_dtypes(include=np.number).columns

print("\nОсновные статистические показатели:")
statistics = df[numeric_columns].agg(["mean", "median", "std"])
statistics.index = ["Среднее", "Медиана", "Стандартное отклонение"]
print(statistics.round(3).to_string())

df[numeric_columns] = df[numeric_columns].fillna(
    df[numeric_columns].median()
)

df["QualityCategory"] = np.select(
    [df["quality"] <= 4, df["quality"] <= 6],
```

```
    ["плохое", "среднее"],
    default="хорошее"
)

print("\n2. Категории качества:")
print(df[["quality", "QualityCategory"]].head(10).to_string(index=False))

category_counts = df["QualityCategory"].value_counts().reindex(
    ["плохое", "среднее", "хорошее"],
    fill_value=0
)

print("\n3. Количество вин каждой категории:")
print(category_counts)

plt.figure(figsize=(8, 5))
bars = plt.bar(
    category_counts.index,
    category_counts.values,
    color=["tomato", "gold", "mediumseagreen"]
)
plt.bar_label(bars)
plt.title("Распределение вин по категориям качества")
plt.xlabel("Категория качества")
plt.ylabel("Количество вин")
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()

correlation = df["fixed acidity"].corr(df["pH"])

print("\n4. Корреляция между fixed acidity и pH:")
print(f"Коэффициент корреляции: {correlation:.4f}")

plt.figure(figsize=(8, 5))
plt.scatter(
    df["fixed acidity"],
    df["pH"],
    alpha=0.4,
    s=20,
    color="steelblue"
)
plt.title("Зависимость pH от фиксированной кислотности")
plt.xlabel("Фиксированная кислотность (fixed acidity)")
plt.ylabel("pH")
plt.grid(alpha=0.3)
plt.tight_layout()

q1 = df[numeric_columns].quantile(0.25)
q3 = df[numeric_columns].quantile(0.75)
iqr = q3 - q1

lower_bounds = q1 - 1.5 * iqr
upper_bounds = q3 + 1.5 * iqr

outlier_counts = (
    (df[numeric_columns] < lower_bounds)
    | (df[numeric_columns] > upper_bounds)
).sum().sort_values(ascending=False)

print("\n5. Количество выбросов по правилу 1.5 IQR:")
print(outlier_counts)

max_outliers = outlier_counts.max()
outlier_features = outlier_counts[
```

```
    outlier_counts == max_outliers
].index.tolist()

print("\nПризнаки с наибольшим количеством выбросов:")
for column in outlier_features:
    print(f"{column}: {max_outliers}")

df[numeric_columns].plot(
    kind="box",
    subplots=True,
    layout=(3, 4),
    figsize=(16, 11),
    sharey=False
)
plt.suptitle("Поиск выбросов в числовых признаках")
plt.tight_layout(rect=[0, 0, 1, 0.96])

df_standardized = df.copy()

means = df[numeric_columns].mean()
stds = df[numeric_columns].std(ddof=0)
stds = stds.replace(0, 1)

df_standardized[numeric_columns] = (
    df[numeric_columns] - means
) / stds

print("\n6. Стандартизированные данные — первые 5 строк:")
print(df_standardized.head().round(3).to_string(index=False))

print("\nПроверка стандартизации:")
check = pd.DataFrame({
    "Среднее": df_standardized[numeric_columns].mean(),
    "Стандартное отклонение": df_standardized[numeric_columns].std(ddof=0)
})
print(check.round(6).to_string())

plt.show()
```

Результат программы:

Первые 5 строк:

fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.0010	3.00	0.45	8.8	6
6.3	0.30	0.34	1.6	0.049	14.0	132.0	0.9940	3.30	0.49	9.5	6
8.1	0.28	0.40	6.9	0.050	30.0	97.0	0.9951	3.26	0.44	10.1	6
7.2	0.23	0.32	8.5	0.058	47.0	186.0	0.9956	3.19	0.40	9.9	6
7.2	0.23	0.32	8.5	0.058	47.0	186.0	0.9956	3.19	0.40	9.9	6

1. Информация о типах столбцов:

```
<class 'pandas.DataFrame'>
RangeIndex: 4898 entries, 0 to 4897
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
```

```
 0   fixed acidity         4898 non-null   float64
 1   volatile acidity      4898 non-null   float64
 2   citric acid           4898 non-null   float64
 3   residual sugar        4898 non-null   float64
 4   chlorides             4898 non-null   float64
 5   free sulfur dioxide   4898 non-null   float64
 6   total sulfur dioxide  4898 non-null   float64
 7   density               4898 non-null   float64
 8   pH                    4898 non-null   float64
 9   sulphates             4898 non-null   float64
 10  alcohol               4898 non-null   float64
 11  quality               4898 non-null   int64
dtypes: float64(11), int64(1)
memory usage: 459.3 KB
```

Количество пропусков:

```
fixed acidity           0
volatile acidity        0
citric acid             0
residual sugar          0
chlorides               0
free sulfur dioxide     0
total sulfur dioxide    0
density                 0
pH                      0
sulphates               0
alcohol                 0
quality                 0
dtype: int64
```

Основные статистические показатели:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
Среднее	6.855	0.278	0.334	6.391	0.046	35.308	138.361	0.994	3.188	0.490	10.514	5.878
Медиана	6.800	0.260	0.320	5.200	0.043	34.000	134.000	0.994	3.180	0.470	10.400	6.000
Стандартное отклонение	0.844	0.101	0.121	5.072	0.022	17.007	42.498	0.003	0.151	0.114	1.231	0.886

2. Категории качества:

quality	QualityCategory
6	среднее
6	среднее
6	среднее
6	среднее
6	среднее
6	среднее
6	среднее
6	среднее
6	среднее
6	среднее

3. Количество вин каждой категории:
QualityCategory
плохое 183
среднее 3655
хорошее 1060
Name: count, dtype: int64

4. Корреляция между fixed acidity и pH:
Коэффициент корреляции: -0.4259

5. Количество выбросов по правилу 1.5 IQR:
citric acid 270
chlorides 208
quality 200
volatile acidity 186
sulphates 124
fixed acidity 119
pH 75
free sulfur dioxide 50
total sulfur dioxide 19
residual sugar 7
density 5
alcohol 0
dtype: int64

Признаки с наибольшим количеством выбросов:
citric acid: 270

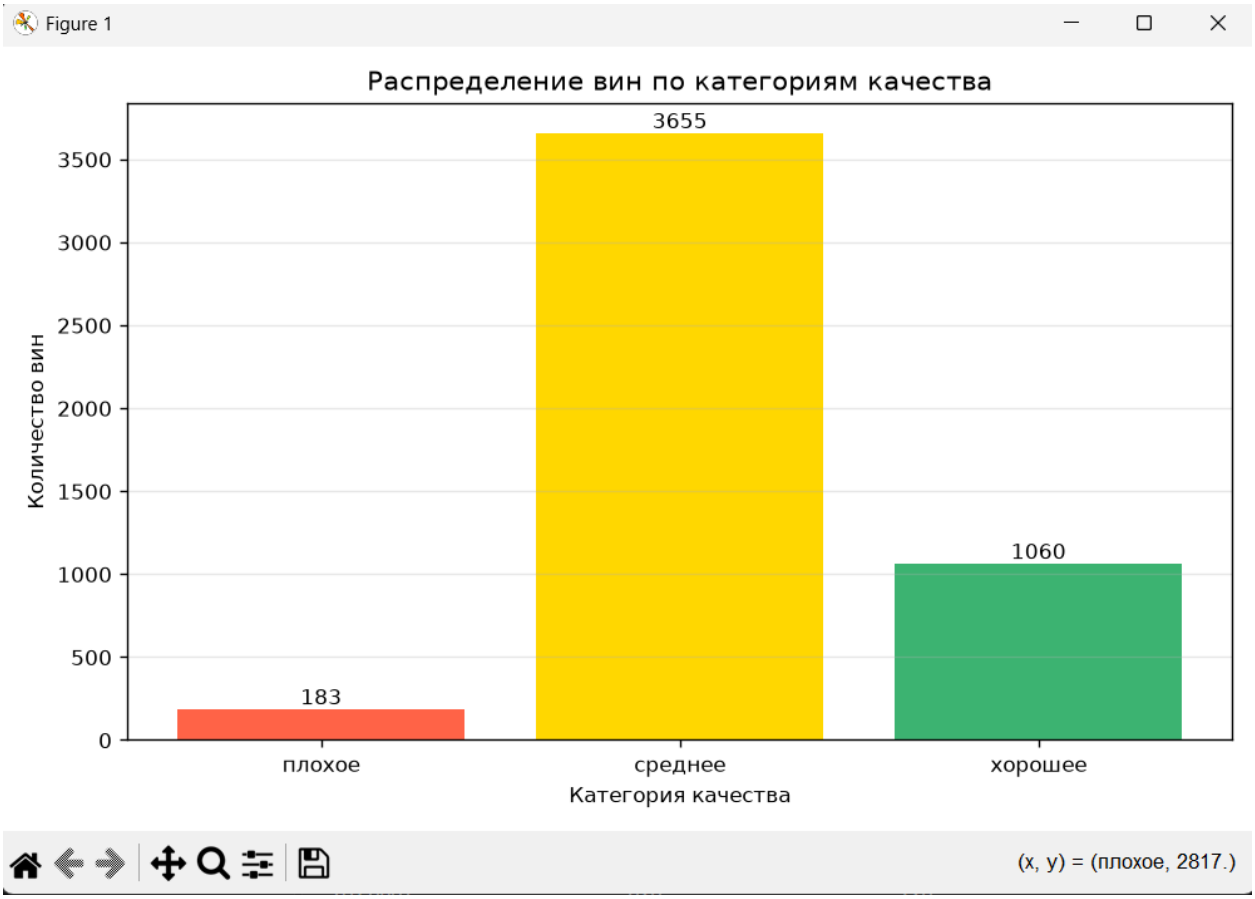
6. Стандартизированные данные — первые 5 строк:

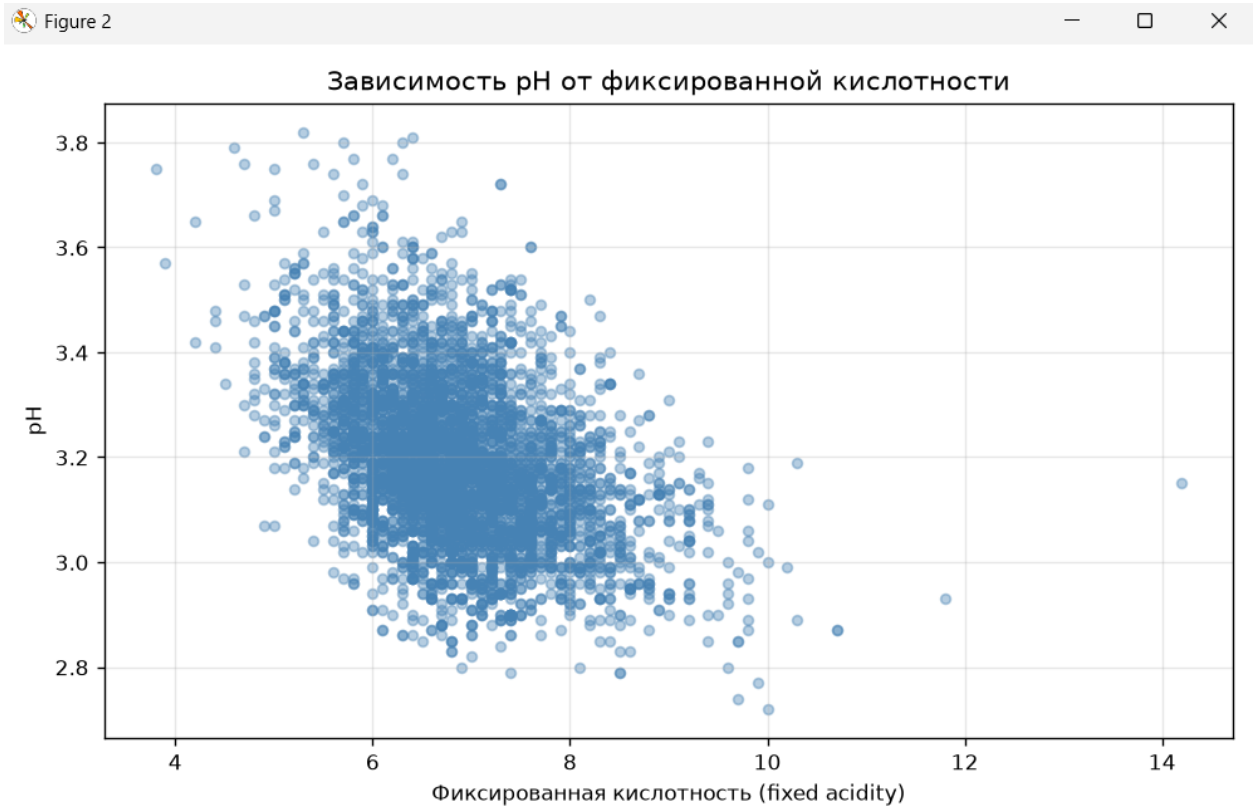
fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	QualityCategory
0.172	-0.082	0.213	2.821	-0.035	0.570	0.745	2.332	-1.247	-0.349	-1.393	0.138	среднее
-0.658	0.216	0.048	-0.945	0.148	-1.253	-0.150	-0.009	0.740	0.001	-0.824	0.138	среднее
1.476	0.017	0.544	0.100	0.194	-0.312	-0.973	0.359	0.475	-0.437	-0.337	0.138	среднее
0.409	-0.479	-0.117	0.416	0.560	0.688	1.121	0.526	0.011	-0.787	-0.499	0.138	среднее
0.409	-0.479	-0.117	0.416	0.560	0.688	1.121	0.526	0.011	-0.787	-0.499	0.138	среднее

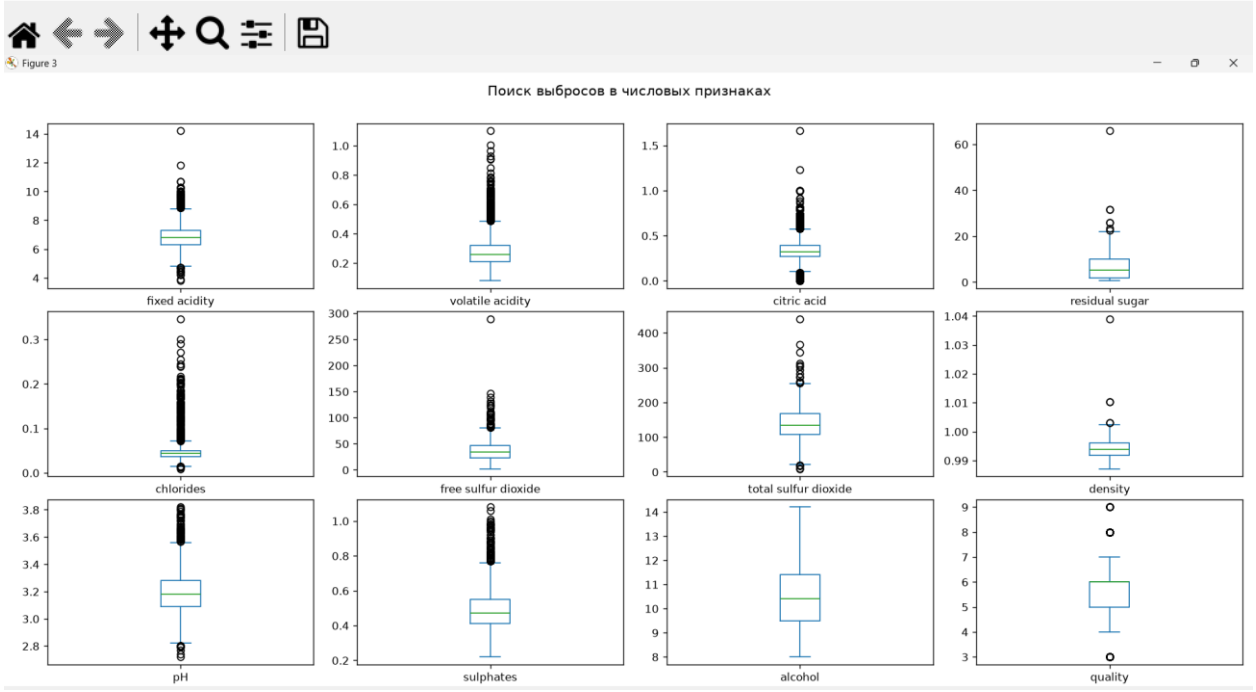
Проверка стандартизации:

	Среднее	Стандартное отклонение
fixed acidity	-0.0	1.0
volatile acidity	0.0	1.0
citric acid	0.0	1.0
residual sugar	-0.0	1.0
chlorides	0.0	1.0
free sulfur dioxide	-0.0	1.0
total sulfur dioxide	-0.0	1.0

density	0.0	1.0
pH	-0.0	1.0
sulphates	-0.0	1.0
alcohol	-0.0	1.0
quality	0.0	1.0




Figure 2
Зависимость pH от фиксированной кислотности
pH
Фиксированная кислотность (fixed acidity)


Figure 3
Поиск выбросов в числовых признаках
fixed acidity
volatile acidity
citric acid
residual sugar
chlorides
free sulfur dioxide
total sulfur dioxide
density
pH
sulphates
alcohol
quality