МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность АС-67

Выполнил
А. Н. Гришкевич,
студент группы АС-67

Проверил
А. А. Крощенко,
ст. преп. кафедры ИИТ,
«___> _____2026 г.

Брест 2026

Цель работы: получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных,такие как очистка, нормализация и работа с различными типами признаков.

Вариант 2

Выборка Boston Housing. Содержит информацию о жилье в разных районах Бостона, включая уровень преступности, количество комнат и медианную стоимость.

Задачи:

1. Загрузите данные и выведите их основные статистические характеристики (.describe()).
2. Постройте матрицу корреляции и визуализируйте ее с помощью тепловой карты (heatmap).
3. Найдите признак, наиболее сильно коррелирующий с целевой переменной MEDV (медианная стоимость дома).
4. Постройте диаграмму рассеяния (scatter plot) для этого признака и MEDV.
5. Нормализуйте все числовые признаки, приведя их к диапазону от 0 до 1.
6. Визуализируйте распределение уровня преступности (CRIM) с помощью гистограммы.

Выполнение:

Код программы:

```
from pathlib import Path
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import MinMaxScaler

folder = Path(__file__).resolve().parent
data = pd.read_csv(folder / "BostonHousing.csv")

data.columns = data.columns.str.strip()

print("Количество записей:", len(data))
print("Количество признаков:", len(data.columns))

print("\nСТАТИСТИЧЕСКИЕ ХАРАКТЕРИСТИКИ")
print(data.describe().round(3))

analysis_data = data.drop(columns=["CAT. MEDV"], errors="ignore")

correlation = analysis_data.corr(numeric_only=True)

plt.figure(figsize=(13, 10))
sns.heatmap(
    correlation,
    annot=True,
    fmt=".2f",
```

```
    cmap="coolwarm",
    center=0
)
plt.title("Матрица корреляции признаков Boston Housing")
plt.tight_layout()
plt.savefig(folder / "correlation_heatmap.png")
plt.show()

correlations = correlation["MEDV"].drop("MEDV")
best_feature = correlations.abs().idxmax()
best_value = correlations[best_feature]

print("\nКОРРЕЛЯЦИЯ С MEDV")
print(correlations.sort_values(key=abs, ascending=False).round(4))

print("\nНаиболее сильно коррелирующий признак:", best_feature)
print("Коэффициент корреляции:", round(best_value, 4))

plt.figure(figsize=(8, 6))
sns.scatterplot(
    data=data,
    x=best_feature,
    y="MEDV"
)
plt.title(f"Зависимость MEDV от {best_feature}")
plt.xlabel(best_feature)
plt.ylabel("MEDV")
plt.tight_layout()
plt.savefig(folder / "scatter_plot.png")
plt.show()

normalized_data = data.copy()

numeric_columns = normalized_data.select_dtypes(
    include=["number"]
).columns

scaler = MinMaxScaler()

normalized_data[numeric_columns] = scaler.fit_transform(
    normalized_data[numeric_columns]
)

normalized_data.to_csv(
    folder / "BostonHousing_normalized.csv",
    index=False
)

print("\nНОРМАЛИЗАЦИЯ")
print("Все числовые столбцы приведены к диапазону от 0 до 1.")
print("Минимальные значения:")
print(normalized_data[numeric_columns].min().round(3))

print("\nМаксимальные значения:")
print(normalized_data[numeric_columns].max().round(3))

plt.figure(figsize=(8, 6))
sns.histplot(
    data=data,
    x="CRIM",
    bins=30,
    kde=True
)
plt.title("Распределение уровня преступности (CRIM)")
```

```
plt.xlabel("CRIM")
plt.ylabel("Количество районов")
plt.tight_layout()
plt.savefig(folder / "crim_histogram.png")
plt.show()

print("\nРабота программы завершена.")
```

Результат программы:

Количество записей: 506
Количество признаков: 14

СТАТИСТИЧЕСКИЕ ХАРАКТЕРИСТИКИ

	CRIM	ZN	INDUS	CHAS	NOX	RM	...	RAD	TAX	PTRATIO	LSTAT	MEDV	CAT. MEDV
count	506.000	506.000	506.000	506.000	506.000	506.000	...	506.000	506.000	506.000	506.000	506.000	506.000
mean	3.614	11.364	11.137	0.069	0.555	6.285	...	9.549	408.237	18.456	12.653	22.533	0.166
std	8.602	23.322	6.860	0.254	0.116	0.703	...	8.707	168.537	2.165	7.141	9.197	0.372
min	0.006	0.000	0.460	0.000	0.385	3.561	...	1.000	187.000	12.600	1.730	5.000	0.000
25%	0.082	0.000	5.190	0.000	0.449	5.885	...	4.000	279.000	17.400	6.950	17.025	0.000
50%	0.257	0.000	9.690	0.000	0.538	6.208	...	5.000	330.000	19.050	11.360	21.200	0.000
75%	3.677	12.500	18.100	0.000	0.624	6.624	...	24.000	666.000	20.200	16.955	25.000	0.000
max	88.976	100.000	27.740	1.000	0.871	8.780	...	24.000	711.000	22.000	37.970	50.000	1.000

[8 rows x 14 columns]

КОРРЕЛЯЦИЯ С MEDV
LSTAT -0.7377
RM 0.6954
PTRATIO -0.5078
INDUS -0.4837
TAX -0.4685
NOX -0.4273
CRIM -0.3883
RAD -0.3816
AGE -0.3770
ZN 0.3604
DIS 0.2499
CHAS 0.1753
Name: MEDV, dtype: float64

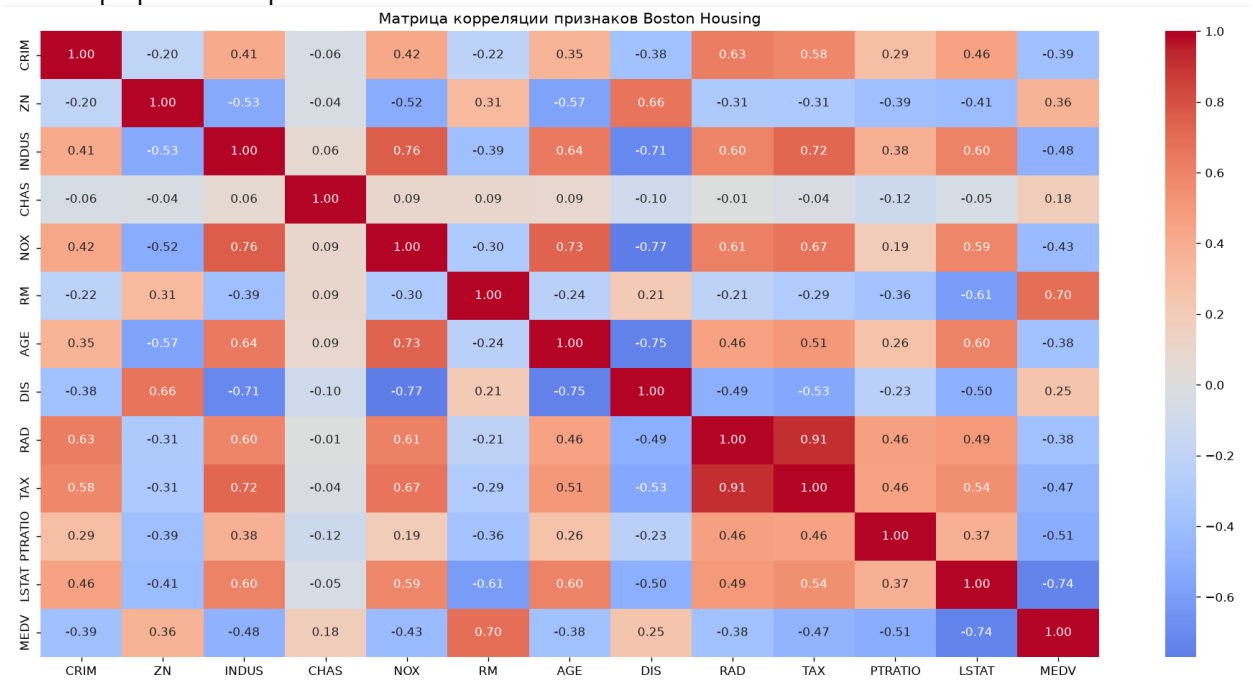
Наиболее сильно коррелирующий признак: LSTAT
Коэффициент корреляции: -0.7377

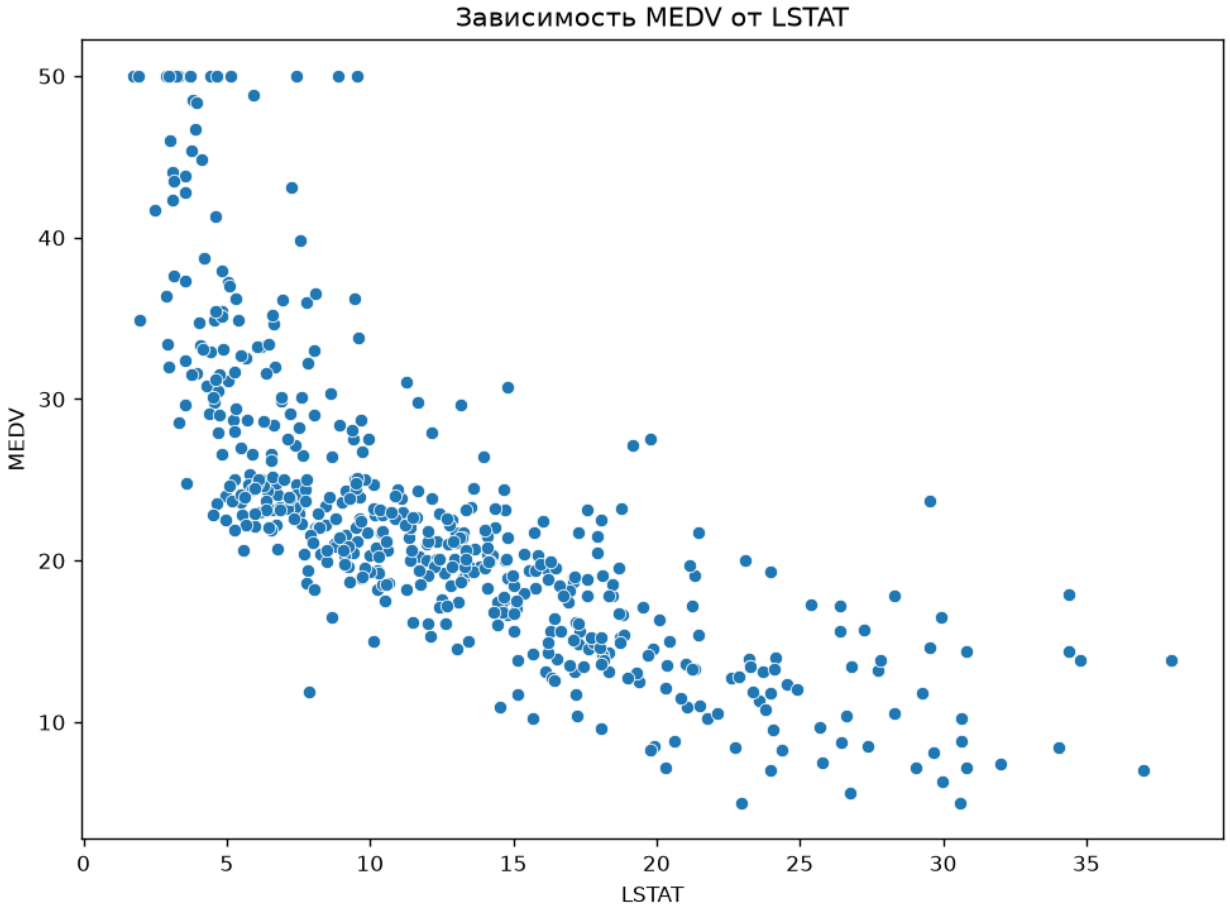
НОРМАЛИЗАЦИЯ
Все числовые столбцы приведены к диапазону от 0 до 1.
Минимальные значения:
CRIM 0.0
ZN 0.0
INDUS 0.0
CHAS 0.0
NOX 0.0
RM 0.0
AGE 0.0
DIS 0.0
RAD 0.0
TAX 0.0
PTRATIO 0.0
LSTAT 0.0
MEDV 0.0
CAT. MEDV 0.0
dtype: float64

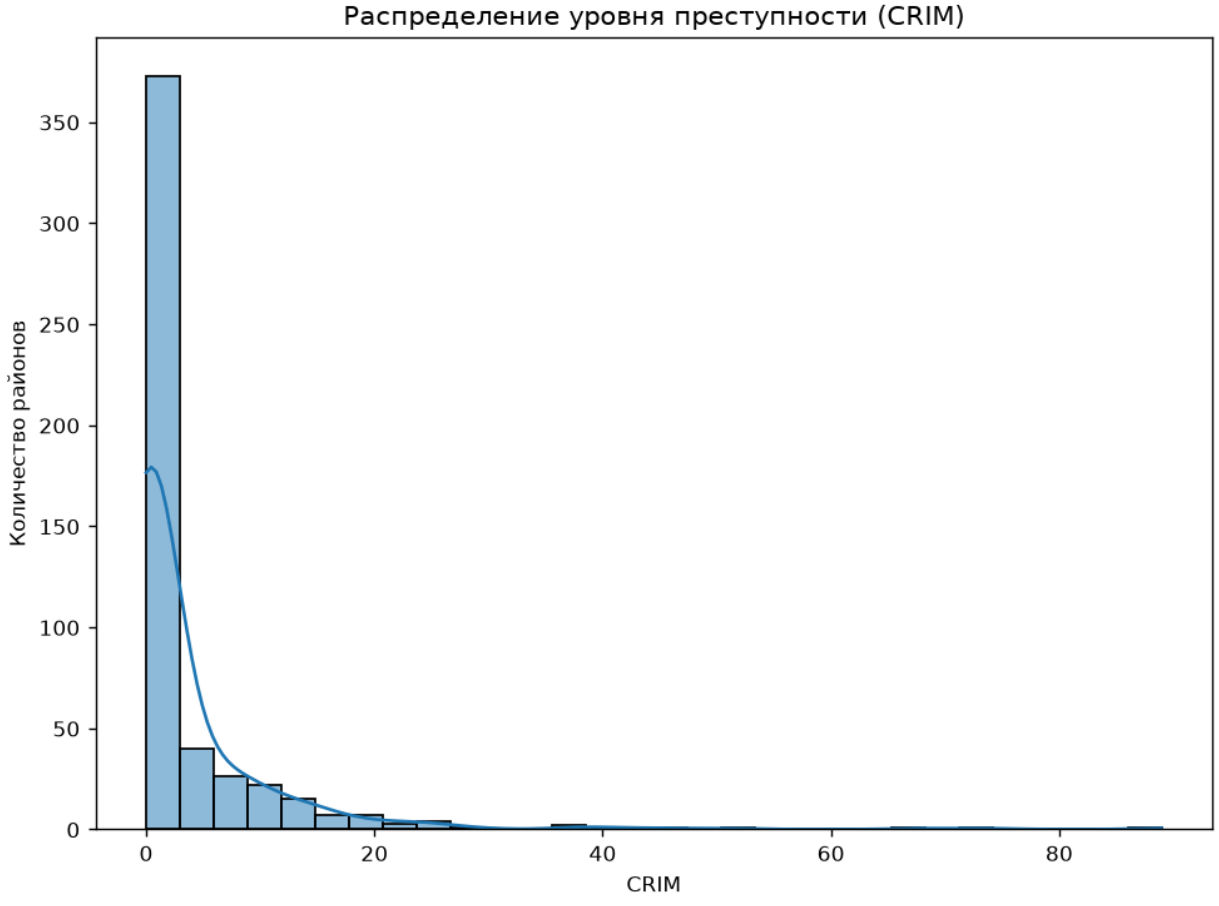
Максимальные значения:

CRIM 1.0
ZN 1.0
INDUS 1.0
CHAS 1.0
NOX 1.0
RM 1.0
AGE 1.0
DIS 1.0
RAD 1.0
TAX 1.0
PTRATIO 1.0
LSTAT 1.0
MEDV 1.0
CAT. MEDV 1.0
dtype: float64

Работа программы завершена.




Зависимость MEDV от LSTAT
MEDV
LSTAT
50
40
30
20
10
0
5
10
15
20
25
30
35


Распределение уровня преступности (CRIM)
Количество районов
CRIM
350
300
250
200
150
100
50
0
0
20
40
60
80