МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №3

Специальность АС-67

Выполнил
А. Н. Гришкевич,
студент группы АС-67

Проверил
А. А. Крощенко,
ст. преп. кафедры ИИТ,
«___> _____2026 г.

Брест 2026

Цель: На практике сравнить работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Вариант 2

- `Breast Cancer Wisconsin`
- Определить, является ли опухоль злокачественной (`malignant`) или доброкачественной (`benign`);
- **Задания:**
  1. Загрузите данные и выполните стандартизацию признаков;
  2. Разделите данные на обучающую и тестовую части;
  3. Обучите три классификатора: k-NN, Decision Tree и SVM;
  4. Для каждой модели постройте матрицу ошибок и рассчитайте метрики `precision`, `recall` и `F1-score` для класса "злокачественная опухоль";
  5. Сравните модели и укажите, какая из них наиболее надежна для минимизации ложноотрицательных прогнозов (когда злокачественная опухоль определяется как доброкачественная).

M

Выполнение:

Код программы

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import (
    accuracy_score,
    confusion_matrix,
    precision_score,
    recall_score,
    f1_score
)

print("   Запуск задачи классификации (Breast Cancer Wisconsin)")

df = pd.read_csv("breast_cancer.csv")

df = df.drop(columns=["id", "Unnamed: 32"], errors="ignore")

X = df.drop("diagnosis", axis=1)
y = (df["diagnosis"] == "M").astype(int)

print("Количество записей:", len(df))
print("Количество признаков:", X.shape[1])
print("Доброкачественные опухоли:", (y == 0).sum())
print("Злокачественные опухоли:", (y == 1).sum())

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
```

```
)

scaler = StandardScaler()

X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

models = {
    "k-NN": KNeighborsClassifier(n_neighbors=5),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "SVM": SVC(kernel="rbf", C=1.0, gamma="scale")
}

results = []

for name, model in models.items():

    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred, pos_label=1)
    recall = recall_score(y_test, y_pred, pos_label=1)
    f1 = f1_score(y_test, y_pred, pos_label=1)

    cm = confusion_matrix(y_test, y_pred, labels=[0, 1])

    tn, fp, fn, tp = cm.ravel()

    results.append({
        "Модель": name,
        "Accuracy": accuracy,
        "Precision": precision,
        "Recall": recall,
        "F1-score": f1,
        "False Negatives": fn
    })

    print(f"\n{name}")
    print(f"Accuracy:  {accuracy:.4f}")
    print(f"Precision: {precision:.4f}")
    print(f"Recall:    {recall:.4f}")
    print(f"F1-score:  {f1:.4f}")

    print("\nМатрица ошибок:")
    print(cm)

    print("\nАнализ матрицы ошибок:")
    print(f"TN: {tn}")
    print(f"FP: {fp}")
    print(f"FN: {fn}")
    print(f"TP: {tp}")

    plt.figure(figsize=(6, 5))

    plt.imshow(
        cm,
        interpolation="nearest",
        cmap=plt.cm.Blues
    )

    plt.title(f"Матрица ошибок — {name}")
    plt.colorbar()

    plt.xticks(
        [0, 1],
        ["Доброкачественная", "Злокачественная"],
        rotation=15
```

```
    )

    plt.yticks(
        [0, 1],
        ["Доброкачественная", "Злокачественная"]
    )

    thresh = cm.max() / 2

    for i in range(2):
        for j in range(2):
            plt.text(
                j,
                i,
                str(cm[i, j]),
                ha="center",
                va="center",
                color="white" if cm[i, j] > thresh else "black"
            )

    plt.xlabel("Предсказанный класс")
    plt.ylabel("Фактический класс")
    plt.tight_layout()
    plt.show()

results = pd.DataFrame(results)

print("\nСРАВНЕНИЕ МОДЕЛЕЙ")
print(results.to_string(
    index=False,
    float_format=lambda x: f"{x:.4f}"
))

best_model = results.sort_values(
    by=["False Negatives", "Recall"],
    ascending=[True, False]
).iloc[0]

print("\nНАИБОЛЕЕ НАДЕЖНАЯ МОДЕЛЬ")
print(best_model["Модель"])
print("Количество ложноотрицательных прогнозов:", int(best_model["False Negatives"]))
print(f"Recall: {best_model['Recall']:.4f}")
```

Результат:

Запуск задачи классификации (Breast Cancer Wisconsin)
Количество записей: 569
Количество признаков: 30
Доброкачественные опухоли: 357
Злокачественные опухоли: 212

k-NN
Accuracy: 0.9561
Precision: 0.9744
Recall: 0.9048
F1-score: 0.9383

Матрица ошибок:
[[71 1]
[4 38]]

Анализ матрицы ошибок:
TN: 71
FP: 1
FN: 4

TP: 38

Decision Tree
Accuracy: 0.9298
Precision: 0.9048
Recall: 0.9048
F1-score: 0.9048

Матрица ошибок:
[[68 4]
 [4 38]]

Анализ матрицы ошибок:
TN: 68
FP: 4
FN: 4
TP: 38

SVM
Accuracy: 0.9737
Precision: 1.0000
Recall: 0.9286
F1-score: 0.9630

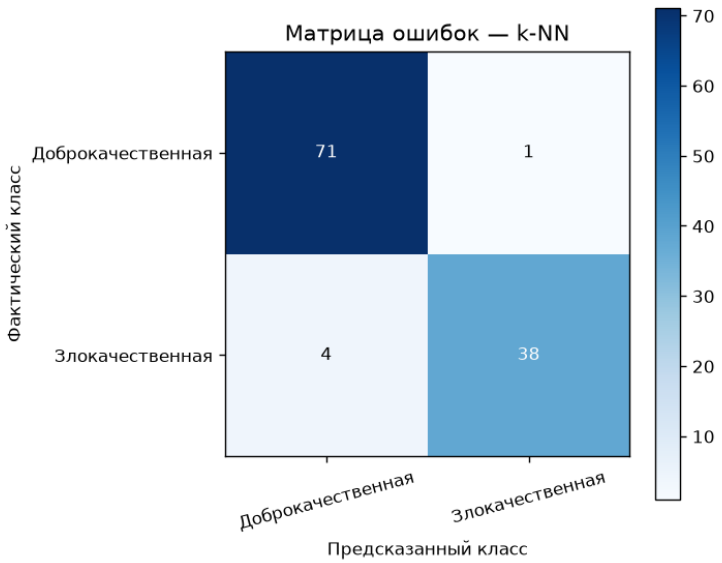
Матрица ошибок:
[[72 0]
 [3 39]]

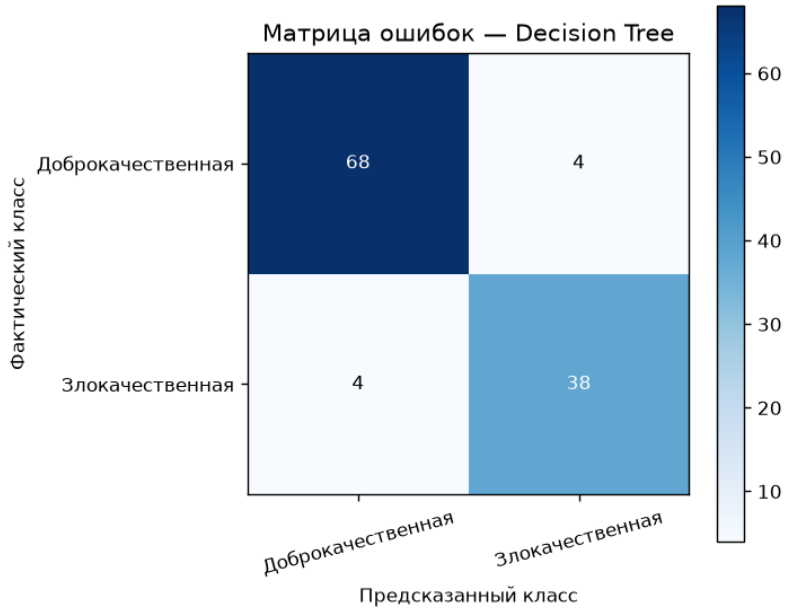
Анализ матрицы ошибок:
TN: 72
FP: 0
FN: 3
TP: 39

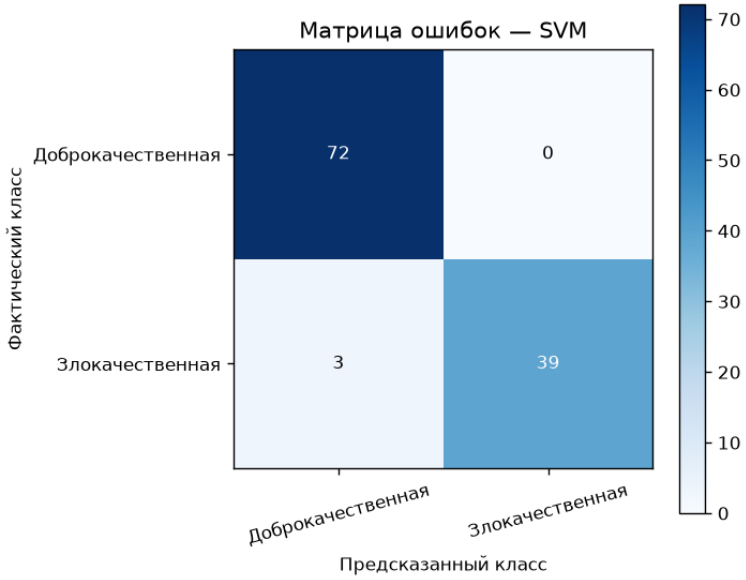
СРАВНЕНИЕ МОДЕЛЕЙ

Модель	Accuracy	Precision	Recall	F1-score	False Negatives
k-NN	0.9561	0.9744	0.9048	0.9383	4
Decision Tree	0.9298	0.9048	0.9048	0.9048	4
SVM	0.9737	1.0000	0.9286	0.9630	3

НАИБОЛЕЕ НАДЕЖНАЯ МОДЕЛЬ
SVM
Количество ложноотрицательных прогнозов: 3
Recall: 0.9286

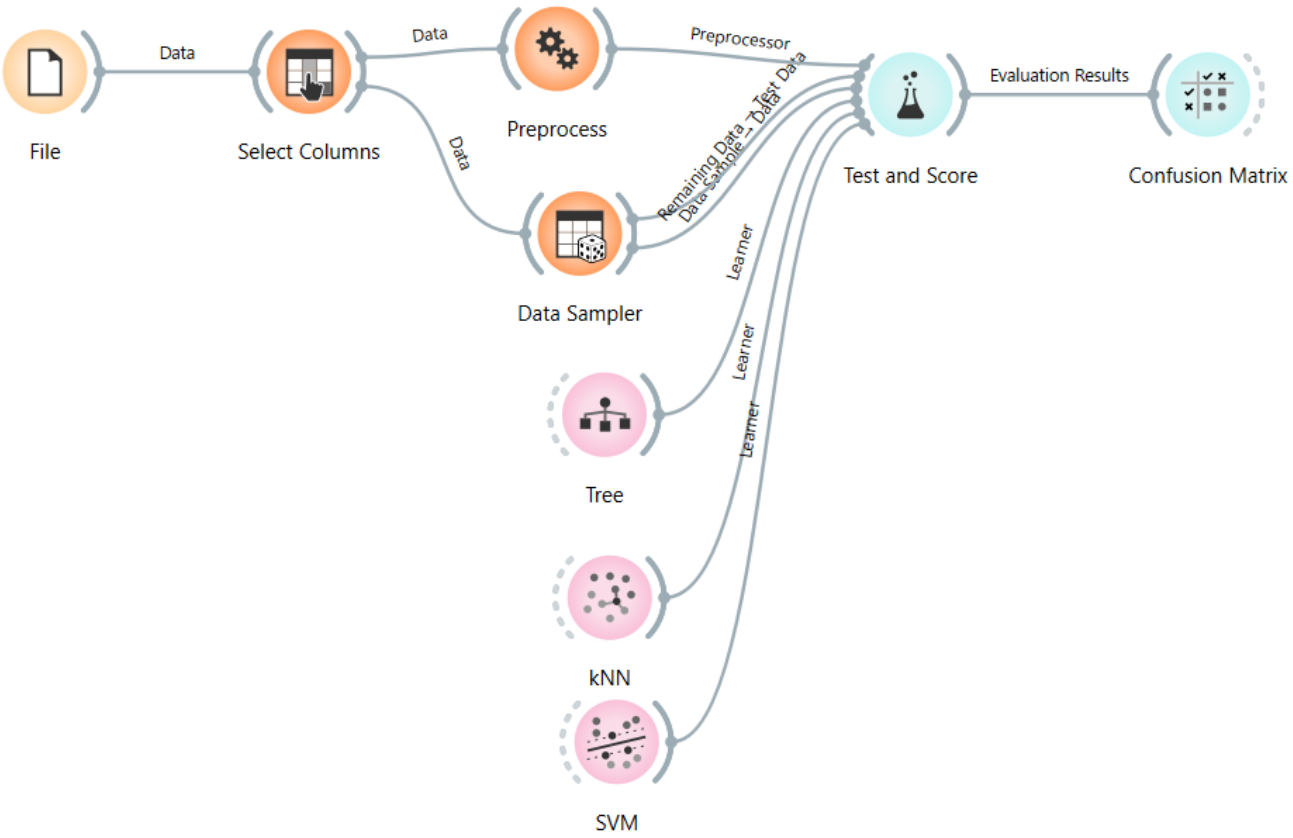


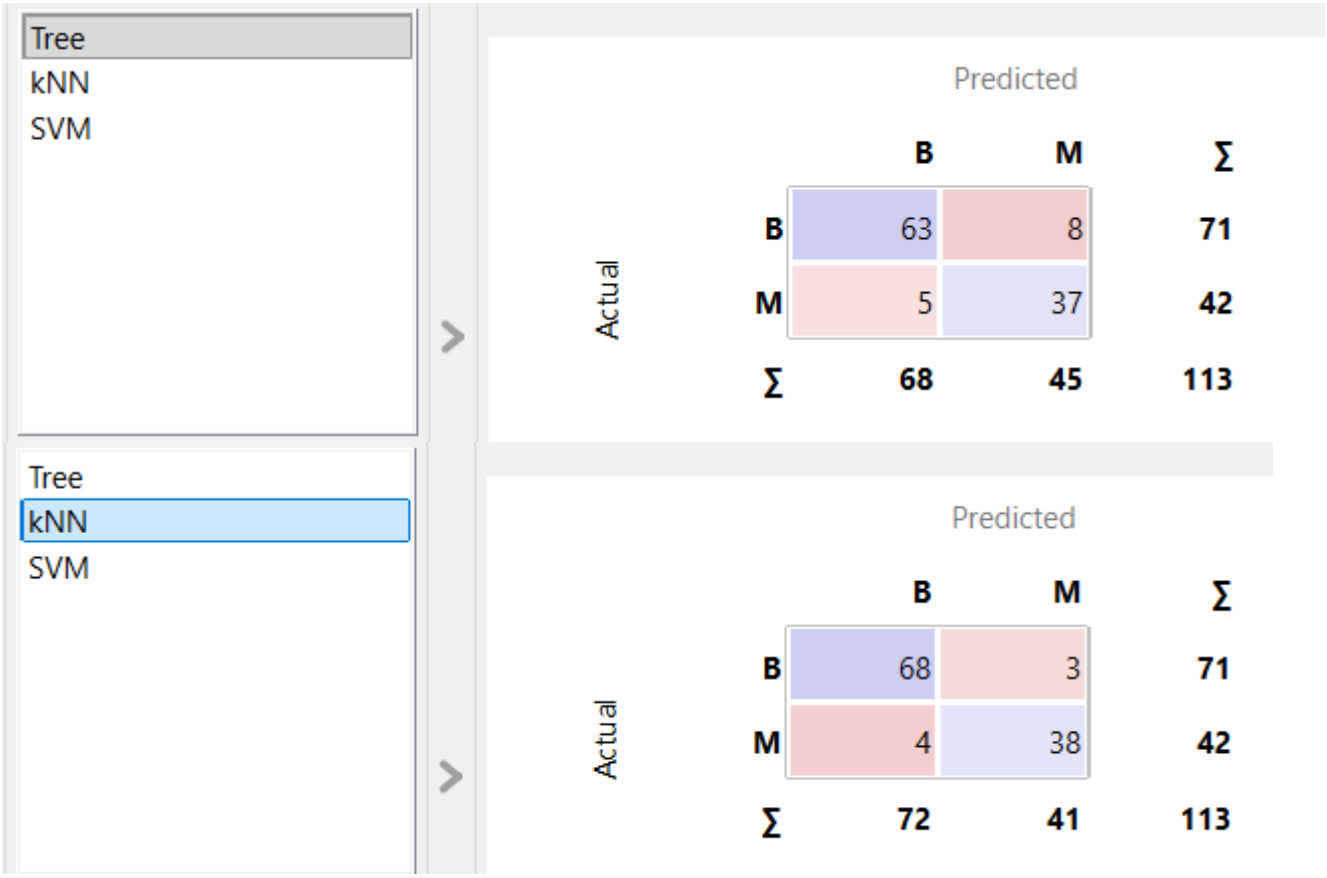


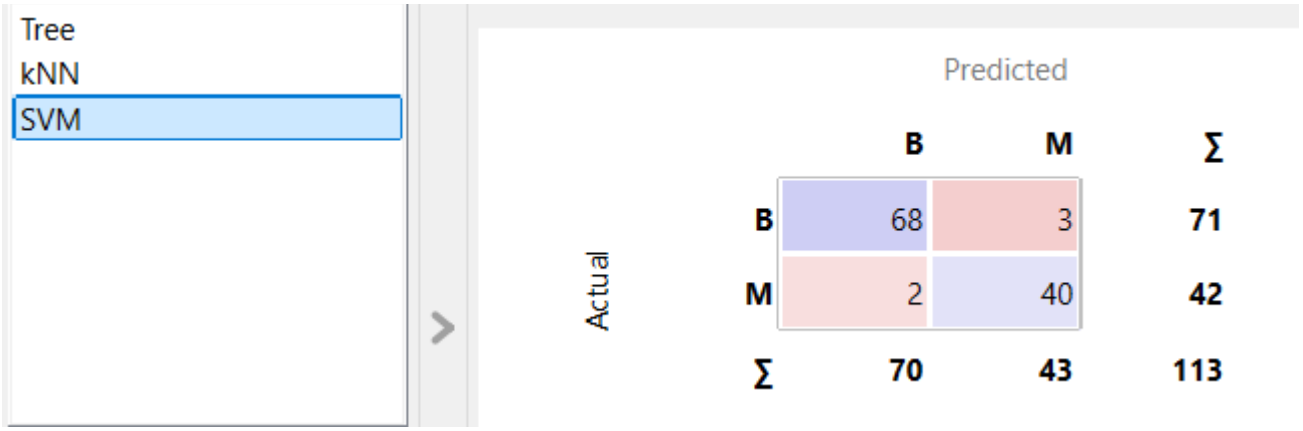


Результаты в Orange:

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.869	0.885	0.886	0.888	0.885	0.758
kNN	0.972	0.938	0.938	0.938	0.938	0.867
SVM	0.996	0.956	0.956	0.956	0.956	0.906


Data
Data
Preprocessor
Evaluation Results
File
Select Columns
Preprocess
Test and Score
Confusion Matrix
Data
Remaining Data
Test Data
Data Sample
Data Sampler
Learner
Learner
Learner
Tree
kNN
SVM


Tree
kNN
SVM
Predicted
B
M
Σ
Actual
B
63
8
71
M
5
37
42
Σ
68
45
113
Tree
kNN
SVM
Predicted
B
M
Σ
Actual
B
68
3
71
M
4
38
42
Σ
72
41
113



Вывод: В ходе лабораторной работы была выполнена классификация опухолей молочной железы с использованием трёх алгоритмов машинного обучения: k-NN, Decision Tree и SVM. Для всех моделей была выполнена стандартизация признаков и оценка качества на тестовой выборке. Наилучший результат показал алгоритм SVM, значение Accuracy которого составило 0,9737, а F1-score — 0,9630. Кроме того, SVM допустила наименьшее количество ложноотрицательных прогнозов — 3 случая, тогда как k-NN и Decision Tree допустили по 4 ошибки. Таким образом, среди рассмотренных моделей SVM оказалась наиболее эффективной для минимизации случаев, когда злокачественная опухоль ошибочно определяется как доброкачественная