МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №1
по дисциплине «ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ»
Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Выполнил:
студент 3 курса
группы АС-67
Доста Е. В.
Проверил:
Крощенко А. А.

2026

Цель работы: Получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. **Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.**

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

Задания по вариантам:

Вариант 2

Выборка Boston Housing. Содержит информацию о жилье в разных районах Бостона, включая уровень преступности, количество комнат и медианную стоимость.

Задачи:

1. Загрузите данные и выведите их основные статистические характеристики (.describe()).
2. Постройте матрицу корреляции и визуализируйте ее с помощью тепловой карты (heatmap).
3. Найдите признак, наиболее сильно коррелирующий с целевой переменной MEDV (медианная стоимость дома).
4. Постройте диаграмму рассеяния (scatter plot) для этого признака и MEDV.
5. Нормализуйте все числовые признаки, приведя их к диапазону от 0 до 1.
6. Визуализируйте распределение уровня преступности (CRIM) с помощью гистограммы.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('BostonHousing.csv')
```

```
print("\nПервые 5 строк:")
print(df.head())


#1 основные статистические характеристики (.describe())
print("\nОписательные статистики (.describe()):")
print(df.describe())


#2 матрица корреляции с помощью тепловая карта (heatmap)
corr = df.corr()

plt.figure(figsize=(14, 10))
plt.imshow(corr, cmap="coolwarm")
plt.colorbar(label="Коэффициент корреляции")

plt.xticks(range(len(corr.columns)), corr.columns, rotation=90)
plt.yticks(range(len(corr.columns)), corr.columns)

for i in range(len(corr.columns)):
    for j in range(len(corr.columns)):
        plt.text(
            j, i, f"{corr.iloc[i, j]:.2f}",
            ha="center", va="center",
            color="black", fontsize=8
        )

plt.title("Корреляционная матрица Boston Housing")
plt.tight_layout()
plt.show()


#3 признак наиболее сильно коррелирующий с MEDV (медианная стоимость дома)
corr_medv = corr["MEDV"].drop("MEDV").sort_values(key=abs, ascending=False)

top_feature = corr_medv.index[1]
top_value = corr_medv.iloc[1]

print(f"\nНаиболее сильная корреляция с MEDV: {top_feature}")
print(f"Коэффициент корреляции: {top_value:.3f}")


#4 Диаграмма рассеяния для top_feature и MEDV
plt.figure(figsize=(8, 6))
plt.scatter(df[top_feature], df["MEDV"], alpha=0.7)
plt.xlabel(top_feature)
plt.ylabel("MEDV (медианная стоимость дома)")
plt.title(f"Зависимость MEDV от {top_feature}")
plt.grid(True)
plt.show()


#5 Нормализация числовых признаков к диапазону [0, 1]
X = df.drop(columns=["MEDV"])
y = df["MEDV"]

X_norm = (X - X.min()) / (X.max() - X.min())

df_norm = X_norm.copy()
df_norm["MEDV"] = y.values


#6 Гистограмма распределения CRIM
plt.figure(figsize=(10, 6))
```

```
plt.hist(df["CRIM"], bins=40, color="skyblue", edgecolor="black")
plt.xlabel("CRIM (уровень преступности)")
plt.ylabel("Частота")
plt.title("Распределение уровня преступности CRIM")
plt.grid(axis="y", alpha=0.3)
plt.show()
```

Результат программы:

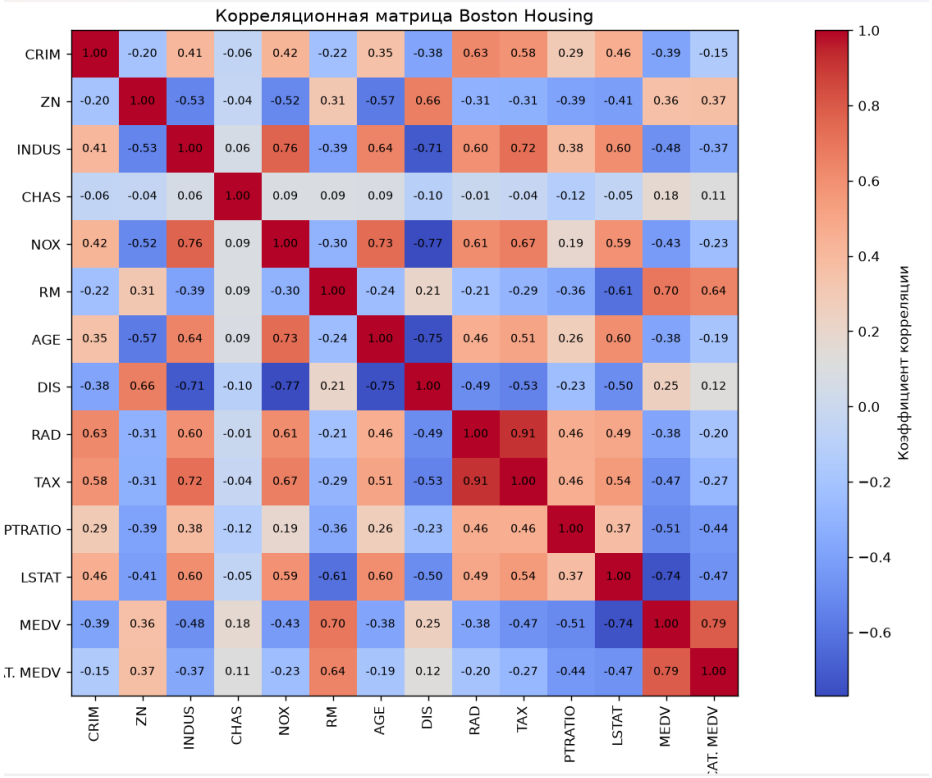
```
Первые 5 строк:
      CRIM    ZN  INDUS  CHAS    NOX  ...  TAX  PTRATIO  LSTAT  MEDV  CAT. MEDV
0  0.00632  18.0   2.31     0  0.538  ...  296     15.3   4.98  24.0          0
1  0.02731   0.0   7.07     0  0.469  ...  242     17.8   9.14  21.6          0
2  0.02729   0.0   7.07     0  0.469  ...  242     17.8   4.03  34.7          1
3  0.03237   0.0   2.18     0  0.458  ...  222     18.7   2.94  33.4          1
4  0.06905   0.0   2.18     0  0.458  ...  222     18.7   5.33  36.2          1

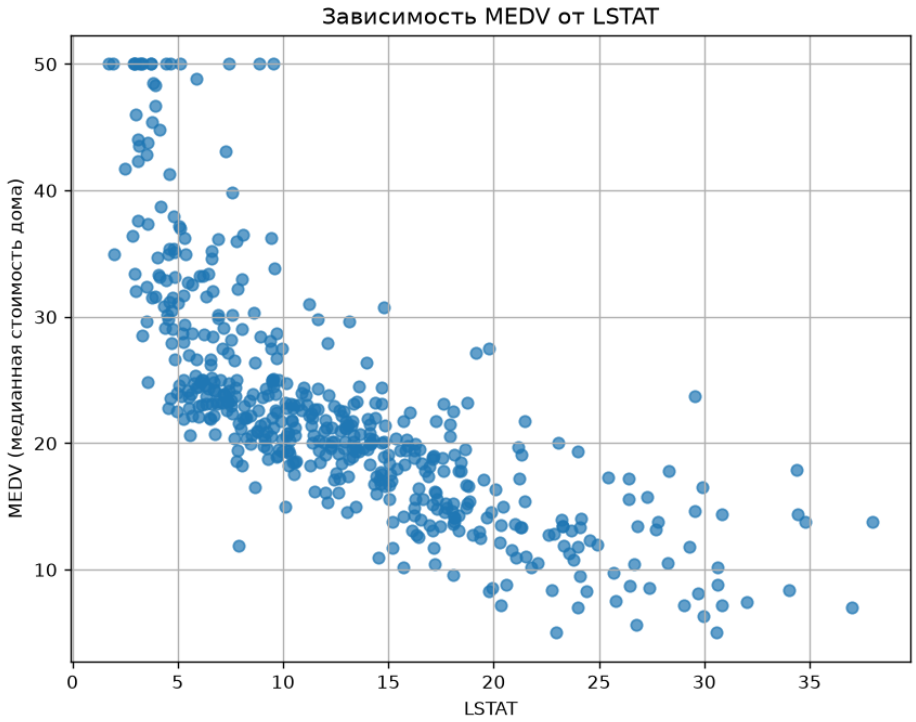
[5 rows x 14 columns]

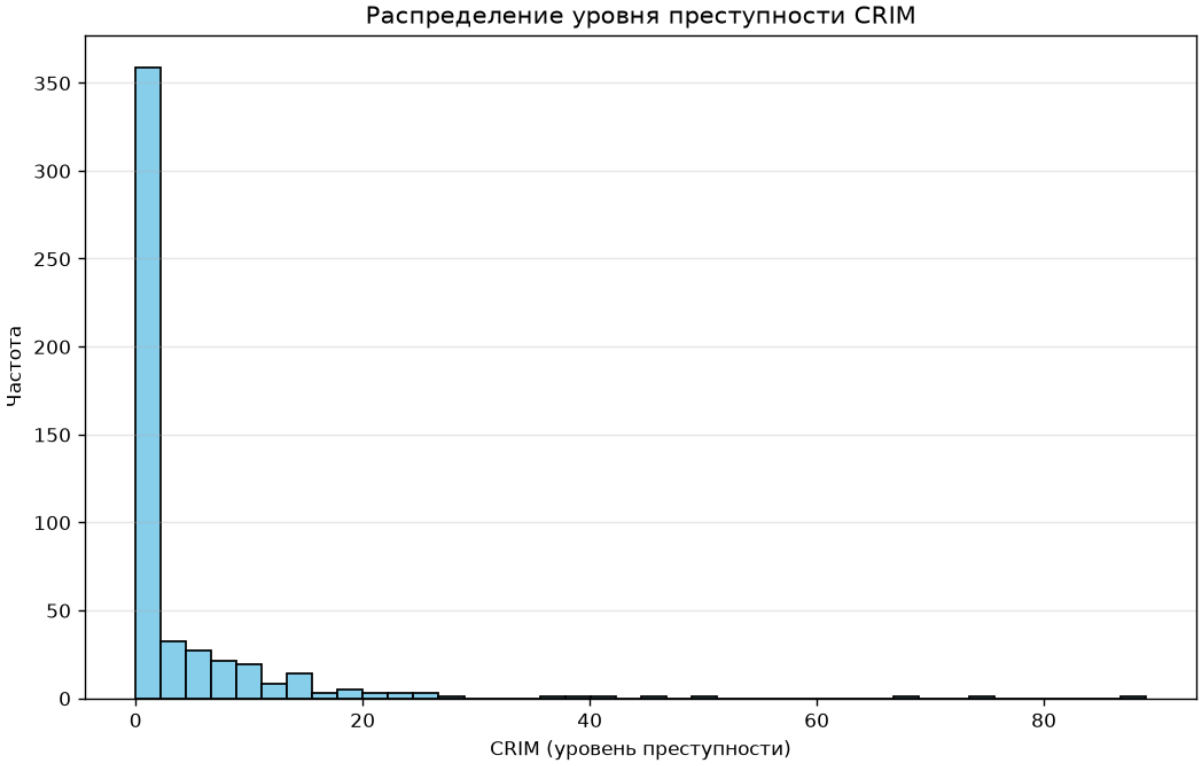
Описательные статистики (.describe()):
             CRIM          ZN       INDUS  ...       LSTAT        MEDV   CAT. MEDV
count  506.000000  506.000000  506.000000  ...  506.000000  506.000000  506.000000
mean     3.613524   11.363636   11.136779  ...   12.653063   22.532806    0.166008
std      8.601545   23.322453    6.860353  ...    7.141062    9.197104    0.372456
min      0.006320    0.000000    0.460000  ...    1.730000    5.000000    0.000000
25%      0.082045    0.000000    5.190000  ...    6.950000   17.025000    0.000000
50%      0.256510    0.000000    9.690000  ...   11.360000   21.200000    0.000000
75%      3.677083   12.500000   18.100000  ...   16.955000   25.000000    0.000000
max     88.976200  100.000000   27.740000  ...   37.970000   50.000000    1.000000

[8 rows x 14 columns]

Наиболее сильная корреляция с MEDV: LSTAT
Коэффициент корреляции: -0.738
```







Вывод: Получил практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научился выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.