МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №3
по дисциплине «ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ»
Тема: «Сравнение классических методов классификации»

Выполнил:
студент 3 курса
группы АС-67
Доста Е. В.
Проверил:
Крощенко А. А.

2026

Цель работы: На практике сравнить работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке три модели: k-NN, Decision Tree и SVM;
4. Для модели k-NN исследовать, как меняется качество при разном количестве соседей (k);
5. Оценить точность каждой модели на тестовой выборке;
6. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 2

- `Breast Cancer Wisconsin`
- Определить, является ли опухоль злокачественной (`malignant`) или доброкачественной (`benign`);
- **Задания:**
    1. Загрузите данные и выполните стандартизацию признаков;
    2. Разделите данные на обучающую и тестовую части;
    3. Обучите три классификатора: k-NN, Decision Tree и SVM;
    4. Для каждой модели постройте матрицу ошибок и рассчитайте метрики `precision`, `recall` и `F1-score` для класса "злокачественная опухоль";
    5. Сравните модели и укажите, какая из них наиболее надежна для минимизации ложноотрицательных прогнозов (когда злокачественная опухоль определяется как доброкачественная).

Код программы:

```
import pandas as pd
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import confusion_matrix, classification_report

df = pd.read_csv("breast_cancer.csv")
df = df.loc[:, ~df.columns.str.contains("^Unnamed")]

X = df.drop(columns=["id", "diagnosis"])
y = df["diagnosis"].map({"B": 0, "M": 1})

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y
)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

best_k, best_score = 1, 0
```

```
for k in range(1, 31):
    knn = KNeighborsClassifier(n_neighbors=k)
    score = cross_val_score(knn, X_train, y_train, cv=5).mean()
    if score > best_score:
        best_k, best_score = k, score

print(f"Лучшее k = {best_k} (CV accuracy = {best_score:.4f})\n")

models = {
    f"k-NN (k={best_k})": KNeighborsClassifier(n_neighbors=best_k),
    "Decision Tree":      DecisionTreeClassifier(),
    "SVM":                SVC(kernel="rbf"),
}

for name, model in models.items():
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)

    cm = confusion_matrix(y_test, y_pred, labels=[0, 1])
    cm_df = pd.DataFrame(
        cm,
        index=["Реально benign", "Реально malignant"],
        columns=["Предсказано benign", "Предсказано malignant"]
    )
    tn, fp, fn, tp = cm.ravel()

    print(f"Модель: {name}")
    print("Матрица ошибок:")
    print(cm_df)
    print()
    print(classification_report(
        y_test, y_pred,
        target_names=["benign", "malignant"],
        digits=4
    ))
    print(f"Ложноотрицательных прогнозов (M→B): {fn}")
```

Результат программы:

```
Лучшее k = 3 (CV accuracy = 0.9670)

Модель: k-NN (k=3)
Матрица ошибок:
                 Предсказано benign  Предсказано malignant
Реально benign                   71                      1
Реально malignant                 3                     39
              precision    recall  f1-score   support

      benign     0.9595    0.9861    0.9726        72
   malignant     0.9750    0.9286    0.9512        42

    accuracy                         0.9649       114
   macro avg     0.9672    0.9573    0.9619       114
weighted avg     0.9652    0.9649    0.9647       114

Ложноотрицательных прогнозов (M→B): 3
```

```
Модель: Decision Tree
Матрица ошибок:
                  Предсказано benign  Предсказано malignant
Реально benign                    68                      4
Реально malignant                  5                     37
              precision    recall  f1-score   support

      benign     0.9315    0.9444    0.9379        72
   malignant     0.9024    0.8810    0.8916        42

    accuracy                         0.9211       114
   macro avg     0.9170    0.9127    0.9147       114
weighted avg     0.9208    0.9211    0.9208       114

Ложноотрицательных прогнозов (M→B): 5
```

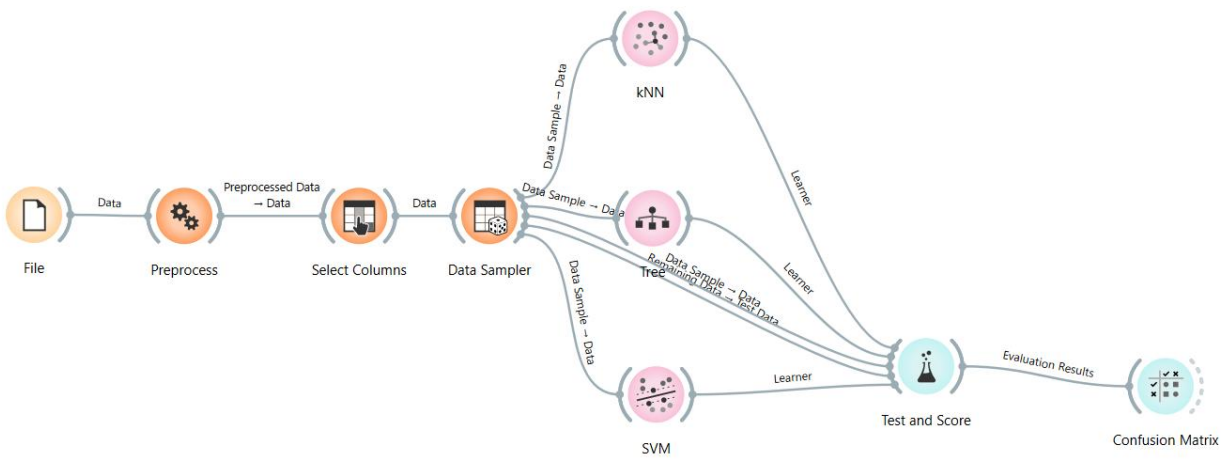
```
Модель: SVM
Матрица ошибок:
                  Предсказано benign  Предсказано malignant
Реально benign                    71                      1
Реально malignant                  2                     40
              precision    recall  f1-score   support

      benign     0.9726    0.9861    0.9793        72
   malignant     0.9756    0.9524    0.9639        42

    accuracy                         0.9737       114
   macro avg     0.9741    0.9692    0.9716       114
weighted avg     0.9737    0.9737    0.9736       114

Ложноотрицательных прогнозов (M→B): 2
```

Orange:



Вывод: На практике сравнил работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научился подбирать гиперпараметры моделей и оценивать их влияние на результат. Наиболее надежной оказалось модель SVM с ложноотрицательным прогнозом 3.