

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №1
по дисциплине «ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ» за 5 семестр
Тема: «Знакомство с анализом данных: предварительная
обработка и визуализация»

Выполнил:

студент 3 курса

группы АС-67

Ковалевич М. М.

Проверил:

Крощенко А. А.

Цель работы: Получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

Задания по вариантам:

Вариант 5

Выборка Adult Census Income. Содержит демографические данные людей из переписи населения США, включая информацию о том, превышает ли их доход \$50 тыс. в год.

Задачи:

1. Загрузите данные и выведите первые 10 строк.


Задание 1													
	age	workclass	fnlwgt	education	education.num	marital.status	...	sex	capital.gain	capital.loss	hours.per.week	native.country	income
0	90	?	77053	HS-grad	9	Widowed	...	Female	0	4356	40	United-States	<=50K
1	82	Private	132870	HS-grad	9	Widowed	...	Female	0	4356	18	United-States	<=50K
2	66	?	186061	Some-college	10	Widowed	...	Female	0	4356	40	United-States	<=50K
3	54	Private	140359	7th-8th	4	Divorced	...	Female	0	3900	40	United-States	<=50K
4	41	Private	264663	Some-college	10	Separated	...	Female	0	3900	40	United-States	<=50K
5	34	Private	216864	HS-grad	9	Divorced	...	Female	0	3770	45	United-States	<=50K
6	38	Private	150601	10th	6	Separated	...	Male	0	3770	40	United-States	<=50K
7	74	State-gov	88638	Doctorate	16	Never-married	...	Female	0	3683	20	United-States	>50K
8	68	Federal-gov	422013	HS-grad	9	Divorced	...	Female	0	3683	40	United-States	<=50K
9	41	Private	70037	Some-college	10	Never-married	...	Male	0	3004	60	?	>50K

2. Проанализируйте столбец workclass. Найдите и замените значения ? на наиболее часто встречающееся значение в этом столбце.

Задание 2

	age	workclass	fnlwgt	education	education.num	marital.status	...	sex	capital.gain	capital.loss	hours.per.week	native.country	income
0	90	Private	77053	HS-grad	9	widowed	...	Female	0	4356	40	United-States	<=50K
1	82	Private	132870	HS-grad	9	widowed	...	Female	0	4356	18	United-States	<=50K
2	66	Private	186061	Some-college	10	widowed	...	Female	0	4356	40	United-States	<=50K
3	54	Private	140359	7th-8th	4	Divorced	...	Female	0	3900	40	United-States	<=50K
4	41	Private	264663	Some-college	10	Separated	...	Female	0	3900	40	United-States	<=50K
5	34	Private	216864	HS-grad	9	Divorced	...	Female	0	3770	45	United-States	<=50K
6	38	Private	150601	10th	6	Separated	...	Male	0	3770	40	United-States	<=50K
7	74	State-gov	88638	Doctorate	16	Never-married	...	Female	0	3683	20	United-States	>50K
8	68	Federal-gov	422013	HS-grad	9	Divorced	...	Female	0	3683	40	United-States	<=50K
9	41	Private	70037	Some-college	10	Never-married	...	Male	0	3004	60	United-States	>50K

3. Определите, сколько в наборе данных мужчин и женщин. Визуализируйте результат.




4. Преобразуйте категориальный признак race в числовой формат.

Задание 4

```
[ 'age', 'workclass', 'fnlwgt', 'education', 'education.num', 'marital.status', 'occupation', 'relationship', 'ntry', 'income', 'race_Aasian-Pac-Islander', 'race_Black', 'race_Other', 'race_White' ]
```

5. Постройте гистограмму распределения возраста (age) для двух групп: тех, кто зарабатывает >50K, и тех, кто зарабатывает <=50K.



6. Создайте новый бинарный признак is_usa на основе столбца native-country.

Задание 6													
	age	workclass	fnlwgt	education	education.num	marital.status	...	income	race_Asian-Pac-Islander	race_Black	race_Other	race_White	is_usa
0	90	Private	77053	HS-grad	9	Widowed	...	<=50K	False	False	False	True	1
1	82	Private	132870	HS-grad	9	Widowed	...	<=50K	False	False	False	True	1
2	66	Private	186061	Some-college	10	Widowed	...	<=50K	False	True	False	False	1
3	54	Private	140359	7th-8th	4	Divorced	...	<=50K	False	False	False	True	1
4	41	Private	264663	Some-college	10	Separated	...	<=50K	False	False	False	True	1
5	34	Private	216864	HS-grad	9	Divorced	...	<=50K	False	False	False	True	1
6	38	Private	150601	10th	6	Separated	...	<=50K	False	False	False	True	1
7	74	State-gov	88638	Doctorate	16	Never-married	...	>50K	False	False	False	True	1
8	68	Federal-gov	422013	HS-grad	9	Divorced	...	<=50K	False	False	False	True	1
9	41	Private	70037	Some-college	10	Never-married	...	>50K	False	False	False	True	0

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np

print('Задание 1')
df = pd.read_csv('adult.csv', sep=',')
print(df.head(10))

print('Задание 2')
high = df['workclass'].value_counts().index[0]

#df['workclass'].isin(['?'])

df['workclass'] = df['workclass'].replace('?', high)
print(df.head(10))
```

```

print('Задание 3')
sex_counts = df['sex'].value_counts()
print(sex_counts)

plt.figure(figsize=(6, 5))
plt.bar(sex_counts.index, sex_counts.values, color=['blue', 'pink'],
edgecolor='black')
plt.title('Распределение по полу')
plt.xlabel('Пол')
plt.ylabel('Количество')
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()

print('Задание 4')
df = pd.get_dummies(df, columns=['race'], prefix='race', drop_first=True)
print(df.columns.tolist())

print('Задание 5')
df['income'] = df['income'].str.replace('.', '', regex=False)

low = df[df['income'] == '<=50K']['age']
high = df[df['income'] == '>50K']['age']

age_min = df['age'].min()
age_max = df['age'].max()
step = 2

bins = np.arange(age_min, age_max + step, step)

plt.figure(figsize=(10, 6))
plt.hist(low, bins = bins, alpha=0.5, label='<=50K', color='steelblue',
edgecolor='black')
plt.hist(high, bins=bins, alpha=0.5, label='>50K', color='tomato',
edgecolor='black')

plt.title('Распределение возраста по уровню дохода')
plt.xlabel('Age')
plt.ylabel('Количество человек')
plt.legend()
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()

print('Задание 6')
df['is_usa'] = np.where(df['native.country'] == 'United-States', 1, 0)
print(df.head(10))

```

Вывод: Получил практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научился выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.