

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №1

по дисциплине «Основы машинного обучения»

Тема: «Знакомство с анализом данных: предварительная
обработка и визуализация»

Выполнил:

студент 2 курса

группы АС-67

Лискович И.Г.

Проверил:

Крощенко А. А.

2026

Цель: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации.

Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

Задания по вариантам:

Вариант 7

Выборка Auto MPG. Содержит технические характеристики различных автомобилей и данные о расходе топлива (миль на галлон). Задачи:


1. Загрузите данные. Обратите внимание, что пропуски в столбце horsepower могут быть обозначены знаком ?.

	mpg	cylinders	displacement	horsepower	weight	acceleration	model year	origin	car name
0	18.0	8	307.0	130.0	3504	12.0	70	1	chevrolet chevelle malibu
1	15.0	8	350.0	165.0	3693	11.5	70	1	buick skylark 320
2	18.0	8	318.0	150.0	3436	11.0	70	1	plymouth satellite
3	16.0	8	304.0	150.0	3433	12.0	70	1	amc rebel sst
4	17.0	8	302.0	140.0	3449	10.5	70	1	ford torino
5	15.0	8	429.0	198.0	4341	10.0	70	1	ford galaxie 500
6	14.0	8	454.0	220.0	4354	9.0	70	1	chevrolet impala
7	14.0	8	440.0	215.0	4312	8.5	70	1	plymouth fury iii
8	14.0	8	455.0	225.0	4425	10.0	70	1	pontiac catalina
9	15.0	8	390.0	190.0	3850	8.5	70	1	amc ambassador dpl

2. Преобразуйте столбец horsepower в числовой формат и заполните пропуски средним значением.

mpg	float64	mean	50%	std
cylinders	int64	23.514573	23.0	7.815984
displacement	float64	5.454774	4.0	1.701004
horsepower	float64	193.425879	148.5	104.269838
weight	int64	104.469388	93.5	38.491160
acceleration	float64	2970.424623	2803.5	846.841774
model year	int64	15.568090	15.5	2.757689
origin	int64	76.010050	76.0	3.697627
car name	object	1.572864	1.0	0.802055
dtype: object		Пропуски в horsepower: 0		
mpg	0	Осталось пропусков: 0		
cylinders	0			
displacement	0			
horsepower	6			
weight	0			
acceleration	0			
model year	0			
origin	0			
car name	0			
dtype: int64				

3. Постройте диаграмму рассеяния, чтобы изучить зависимость расхода топлива (mpg) от веса автомобиля (weight).




4. Преобразуйте категориальный признак origin (страна производства) в числовой.

5. Создайте новый признак age, рассчитав возраст автомобиля относительно года, когда были собраны данные (например, 1983 - model year).

	mpg	cylinders	displacement	horsepower	weight	acceleration	model year	car name	age	origin_1	origin_2	origin_3
0	18.0	8	307.0	130.0	3504	12.0	70	chevrolet chevelle malibu	13	1	0	0
1	15.0	8	350.0	165.0	3693	11.5	70	buick skylark 320	13	1	0	0
2	18.0	8	318.0	150.0	3436	11.0	70	plymouth satellite	13	1	0	0
3	16.0	8	304.0	150.0	3433	12.0	70	amc rebel sst	13	1	0	0
4	17.0	8	302.0	140.0	3449	10.5	70	ford torino	13	1	0	0
5	15.0	8	429.0	198.0	4341	10.0	70	ford galaxie 500	13	1	0	0
6	14.0	8	454.0	220.0	4354	9.0	70	chevrolet impala	13	1	0	0
7	14.0	8	440.0	215.0	4312	8.5	70	plymouth fury iii	13	1	0	0
8	14.0	8	455.0	225.0	4425	10.0	70	pontiac catalina	13	1	0	0
9	15.0	8	390.0	190.0	3850	8.5	70	amc ambassador dpl	13	1	0	0

6. Визуализируйте распределение количества цилиндров (cylinders) с помощью столбчатой диаграммы.



Код:

```
import pandas as pd

import matplotlib.pyplot as plt

def main():

    df = pd.read_csv("auto-mpg.csv", sep=";", na_values='?')

    print(df.head(10))

    print(df.dtypes)

    print(df.isnull().sum())

    print(df.describe().T[['mean', '50%', 'std']])

    df['horsepower'] = pd.to_numeric(df['horsepower'], errors='coerce')

    mean_horsepower = df['horsepower'].mean()

    df['horsepower'] = df['horsepower'].fillna(mean_horsepower)

    print(f"Пропуски в horsepower: {df['horsepower'].isnull().sum()}")

    df['age'] = 83 - df['model year']

    df = pd.get_dummies(df, columns=['origin'], dtype=int)

    plt.figure(figsize=(10,6))

    plt.scatter(df['weight'], df['mpg'], alpha=0.7, color='royalblue', edgecolors='k')

    plt.title('Зависимость расхода топлива (mpg) от веса автомобиля (weight)', fontsize=14)

    plt.xlabel('Вес автомобиля (weight)', fontsize=12)

    plt.ylabel('Расход топлива (mpg)', fontsize=12)

    plt.grid(True, linestyle='--', alpha=0.5)

    plt.show()

    plt.figure(figsize=(8, 5))

    cylinder_counts = df["cylinders"].value_counts().sort_index()

    plt.bar(

        cylinder_counts.index,

        cylinder_counts.values,

        edgecolor="k",

        color="salmon"

    )

    plt.title("Распределение количества цилиндров")

    plt.xlabel("Количество цилиндров")
```

```
plt.ylabel("Количество автомобилей")

plt.grid(axis="y", linestyle="--", alpha=0.6)

plt.show()

print(f"Осталось пропусков: {df.isnull().sum().sum()}")

print(df.head(10))

if __name__ == "__main__":
    main()
```

Вывод: Я познакомился с Pandas и Matplotlib и научился их применять для анализа данных.