МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №2

по дисциплине «Основы машинного обучения»

Тема: «Линейные модели для задач регрессии и классификации»

Выполнил:
студент 2 курса
группы АС-67
Лискович И.Г.

Проверил:
Крощенко А. А.

2026

Цель: Изучить применение линейной и логистической регрессии для решения практических задач. Научиться обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты.

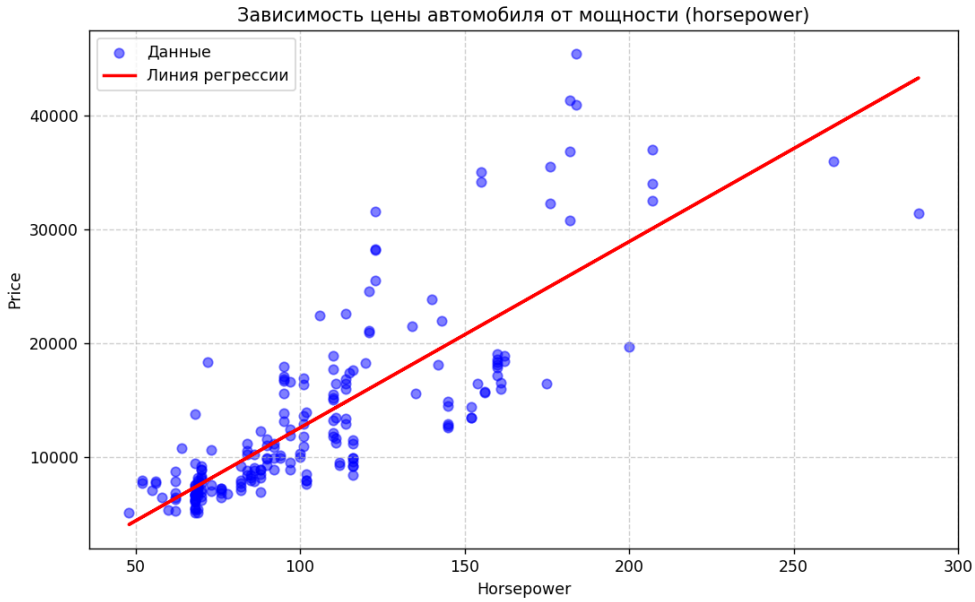
Общее задание: выполнить задания по варианту (регрессия и классификация), построить все требуемые визуализации и рассчитать метрики, написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

Задания по вариантам:

Вариант 7

- Регрессия (Прогнозирование цены автомобиля)
  1. Car Price Prediction
  2. Предсказать цену автомобиля (price)
  3. Задания:
     - загрузите данные. Выберите 5-6 числовых признаков (например, horsepower, citympg, enginesize);
     - обучите модель линейной регрессии;
     - рассчитайте R^2 и MAE;
     - визуализируйте зависимость price от horsepower с линией регрессии.

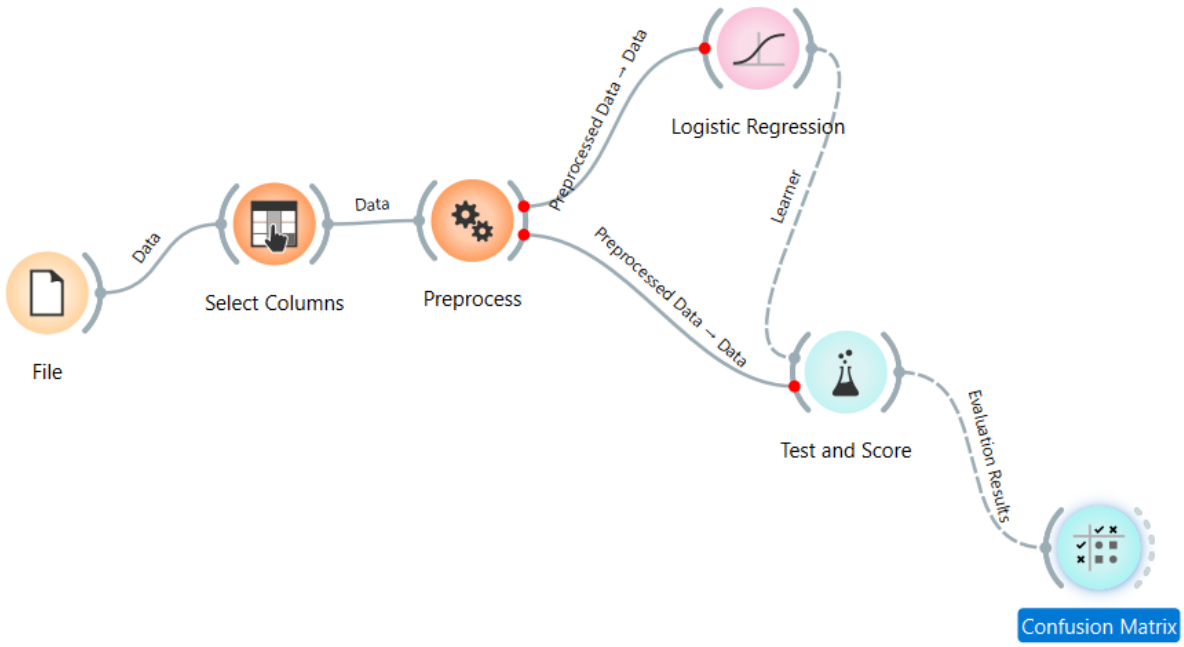


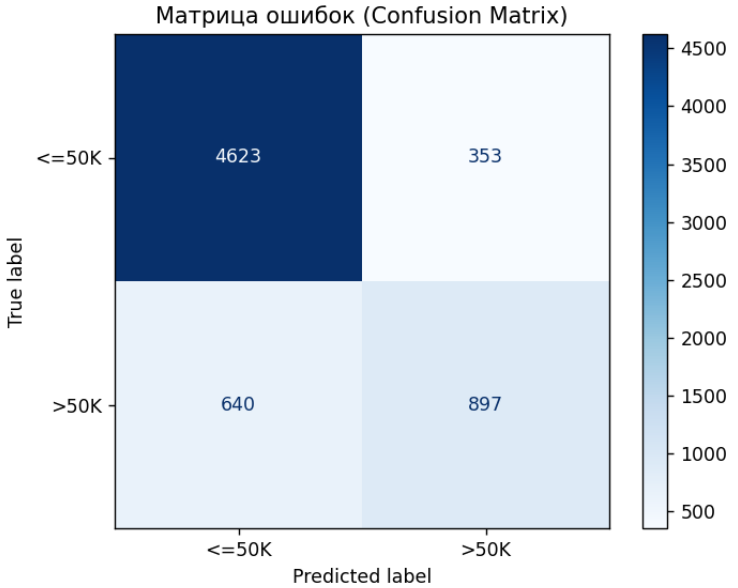
Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	12908843.672	3592.888	2558.508	18.957	18.781	0.797

```
R2 (коэффициент детерминации): 0.8160
MAE (средняя абсолютная ошибка): 2766.5951
```

- Классификация (Прогнозирование уровня дохода)
  1. Adult Census Income

2. Предсказать, превышает ли доход $50 тыс. в год (income >50K)
3. Задания:
   - загрузите данные, обработайте пропуски и
   - категориальные признаки;
   - обучите модель логистической регрессии;
   - рассчитайте Accuracy, Precision и Recall;
   - постройте матрицу ошибок.





Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.900	0.848	0.842	0.841	0.848	0.560

```
Задача Классификации (Доход > 50K)
AUC:      0.903
CA:       0.848
F1:       0.842
Prec:     0.840
Recall:   0.848
MCC:      0.553
```

Код:

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.metrics import mean_absolute_error, r2_score, accuracy_score, precision_score, recall_score,
confusion_matrix, ConfusionMatrixDisplay
from sklearn.preprocessing import StandardScaler


def regression_task():
    try:
        df = pd.read_csv('CarPrice_Assignment.csv')
    except FileNotFoundError:
        print("Ошибка: Файл 'CarPrice_Assignment.csv' не найден. Скачайте датасет и укажите правильный
путь.")
        return

    features = ['horsepower', 'citympg', 'enginesize', 'curbweight', 'highwaympg']
    target = 'price'

    missing_cols = [col for col in features + [target] if col not in df.columns]
    if missing_cols:
        print(f"Внимание: В датасете отсутствуют колонки {missing_cols}. Проверьте названия столбцов.")
        return

    df_reg = df[features + [target]].dropna()

    X = df_reg[features]
    y = df_reg[target]

    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    model = LinearRegression()
    model.fit(X_train, y_train)
```

```
    y_pred = model.predict(X_test)
    r2 = r2_score(y_test, y_pred)
    mae = mean_absolute_error(y_test, y_pred)

    print(f"R2 (коэффициент детерминации): {r2:.4f}")
    print(f"MAE (средняя абсолютная ошибка): {mae:.4f}")

    plt.figure(figsize=(10, 6))
    plt.scatter(df_reg['horsepower'], df_reg['price'], alpha=0.5, color='blue', label='Данные')

    z = np.polyfit(df_reg['horsepower'], df_reg['price'], 1)
    p = np.poly1d(z)
    plt.plot(df_reg['horsepower'], p(df_reg['horsepower']), color='red', linewidth=2, label='Линия
регрессии')

    plt.title('Зависимость цены автомобиля от мощности (horsepower)')
    plt.xlabel('Horsepower')
    plt.ylabel('Price')
    plt.legend()
    plt.grid(True, linestyle='--', alpha=0.6)
    plt.show()


def classification_task():
    try:
        df = pd.read_csv('adult.csv')
    except FileNotFoundError:
        print("Ошибка: Файл 'adult.csv' не найден. Скачайте датасет и укажите правильный путь.")
        return

    df = df.replace(' ?', np.nan)
    df = df.dropna()

    target_col = 'income' if 'income' in df.columns else 'salary'
    if target_col in df.columns:
        df[target_col] = df[target_col].str.strip()
        df['target'] = df[target_col].apply(lambda x: 1 if x in ['>50K', '>50K.'] else 0)
    else:
        print("Ошибка: Не найдена целевая колонка 'income' или 'salary'.")
```

```
        return

    X = df.drop([target_col, 'target'], axis=1)
    y = df['target']

    X = pd.get_dummies(X, drop_first=True)

    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    scaler = StandardScaler()
    X_train_scaled = scaler.fit_transform(X_train)
    X_test_scaled = scaler.transform(X_test)

    model = LogisticRegression(max_iter=1000, random_state=42)
    model.fit(X_train_scaled, y_train)

    y_pred = model.predict(X_test_scaled)

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)

    print(f"Accuracy: {accuracy:.4f}")
    print(f"Precision: {precision:.4f}")
    print(f"Recall: {recall:.4f}")

    cm = confusion_matrix(y_test, y_pred)
    disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['<=50K', '>50K'])

    disp.plot(cmap=plt.cm.Blues)
    plt.title('Матрица ошибок (Confusion Matrix)')
    plt.show()

if __name__ == "__main__":
    regression_task()
    classification_task()
```

Вывод: Я познакомился с регрессией и классификацией.