МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ

«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Кафедра интеллектуальных информационных технологий

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №3

Специальность АС-67

Выполнил:

А. С. Стражевич

Студент группы АС-67

Стражевич А.С.

Проверил:

А. А. Крощенко

Ст. преп. Кафедры ИИТ, «__» ___ 2026 г.

Брест 2026

Цель работы: На практике сравнить работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Ход работы

Вариант 8

Общее задание:

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке три модели: k-NN, Decision Tree и SVM;
4. Для модели k-NN исследовать, как меняется качество при разном количестве соседей (k);
5. Оценить точность каждой модели на тестовой выборке;
6. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Задание по варианту:

Вариант 8

- Seeds
- Классифицировать семена на три сорта пшеницы (Kama, Rosa, Canadian) на основе их геометрических параметров
- **Задания:**
  1. Загрузите и стандартизируйте данные;
  2. Разделите выборку на обучающую и тестовую;
  3. Обучите три классификатора;
  4. Сравните общую точность (accuracy) всех трех моделей;
  5. Визуализируйте данные в 2D (например, с помощью PCA), раскрасив точки в соответствии с предсказаниями лучшей модели.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score
from sklearn.decomposition import PCA

url = "https://archive.ics.uci.edu/ml/machine-learning-
databases/00236/seeds_dataset.txt"

columns = [
    "Area", "Perimeter", "Compactness",
    "Length", "Width", "Asymmetry",
    "Groove", "Class"
]
```

```
data = pd.read_csv(url, sep=r"\s+", header=None, names=columns)

# Названия сортов пшеницы
varieties = {
    1: "Kama",
    2: "Rosa",
    3: "Canadian"
}

data["Class"] = data["Class"].map(varieties)

print("Первые 5 строк датасета:")
print(data.head())

print("\nКоличество объектов каждого сорта:")
print(data["Class"].value_counts())

# 2. Разделение признаков и целевой переменной

X = data.drop("Class", axis=1)
y = data["Class"]

# Делим данные на обучающую и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

# 3. Стандартизация данных

scaler = StandardScaler()

X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# 4. Исследование модели k-NN при разных k

k_values = [1, 3, 5, 7, 9]
knn_results = {}

for k in k_values:
    model = KNeighborsClassifier(n_neighbors=k)
    model.fit(X_train, y_train)

    predictions = model.predict(X_test)
    accuracy = accuracy_score(y_test, predictions)

    knn_results[k] = accuracy

    print(f"k = {k}, Accuracy = {accuracy:.4f}")

# Выбираем лучшее значение k
best_k = max(knn_results, key=knn_results.get)

print("\nЛучшее значение k:", best_k)
```

```
# 5. Обучение трех классификаторов

# k-NN
knn = KNeighborsClassifier(n_neighbors=best_k)
knn.fit(X_train, y_train)

# Дерево решений
tree = DecisionTreeClassifier(random_state=42)
tree.fit(X_train, y_train)

# Метод опорных векторов
svm = SVC(kernel="rbf")
svm.fit(X_train, y_train)

# 6. Оценка точности моделей

models = {
    "k-NN": knn,
    "Decision Tree": tree,
    "SVM": svm
}

results = {}

for name, model in models.items():
    predictions = model.predict(X_test)
    accuracy = accuracy_score(y_test, predictions)

    results[name] = accuracy

    print(f"{name}: Accuracy = {accuracy:.4f}")

# Определяем лучшую модель
best_model_name = max(results, key=results.get)
best_model = models[best_model_name]

print("\nЛучшая модель:", best_model_name)

# 7. График зависимости точности k-NN от количества соседей

plt.figure(figsize=(7, 4))

plt.plot(
    k_values,
    list(knn_results.values()),
    marker="o"
)

plt.xlabel("Количество соседей (k)")
plt.ylabel("Accuracy")
plt.title("Зависимость точности k-NN от значения k")
plt.xticks(k_values)
plt.grid()
plt.show()

# 8. Сравнение точности трех моделей

plt.figure(figsize=(7, 4))
```

```
plt.bar(results.keys(), results.values())

plt.xlabel("Модели")
plt.ylabel("Accuracy")
plt.title("Сравнение точности классификаторов")
plt.ylim(0, 1.05)
plt.grid(axis="y")
plt.show()

# 9. Визуализация данных с помощью PCA

# Преобразуем данные из 7 измерений в 2
pca = PCA(n_components=2)

pca.fit(X_train)

X_test_pca = pca.transform(X_test)

# Получаем предсказания лучшей модели
best_predictions = best_model.predict(X_test)

plt.figure(figsize=(8, 5))

for variety in varieties.values():
    mask = best_predictions == variety

    plt.scatter(
        X_test_pca[mask, 0],
        X_test_pca[mask, 1],
        label=variety
    )

plt.xlabel("Главная компонента 1")
plt.ylabel("Главная компонента 2")
plt.title("Классификация семян пшеницы с помощью PCA")
plt.legend(title="Сорта пшеницы")
plt.grid()
plt.show()

# 10. Итоговые результаты

print("\nИТОГОВОЕ СРАВНЕНИЕ:")

for name, accuracy in results.items():
    print(f"{name}: {accuracy:.4f}")

print("\nЛучшая модель:", best_model_name)
print("Точность:", round(results[best_model_name], 4))
```

Результат программы:

```
PS C:\Users\User\Documents\3 курс (1 семестр)\ОМО\LABA_3> python lab3.py
Первые 5 строк датасета:
    Area  Perimeter  Compactness  Length  Width  Asymmetry  Groove Class
0  15.26      14.84       0.8710   5.763  3.312      2.221   5.220  Kama
1  14.88      14.57       0.8811   5.554  3.333      1.018   4.956  Kama
2  14.29      14.09       0.9050   5.291  3.337      2.699   4.825  Kama
3  13.84      13.94       0.8955   5.324  3.379      2.259   4.805  Kama
4  16.14      14.99       0.9034   5.658  3.562      1.355   5.175  Kama

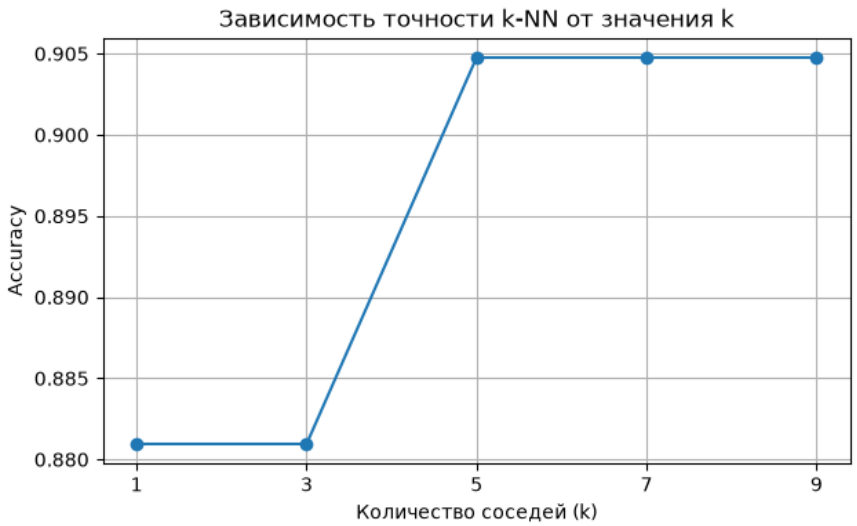
Количество объектов каждого сорта:
Class
Kama        70
Rosa        70
Canadian    70
Name: count, dtype: int64
k = 1, Accuracy = 0.8810
k = 3, Accuracy = 0.8810
k = 5, Accuracy = 0.9048
k = 7, Accuracy = 0.9048
k = 9, Accuracy = 0.9048

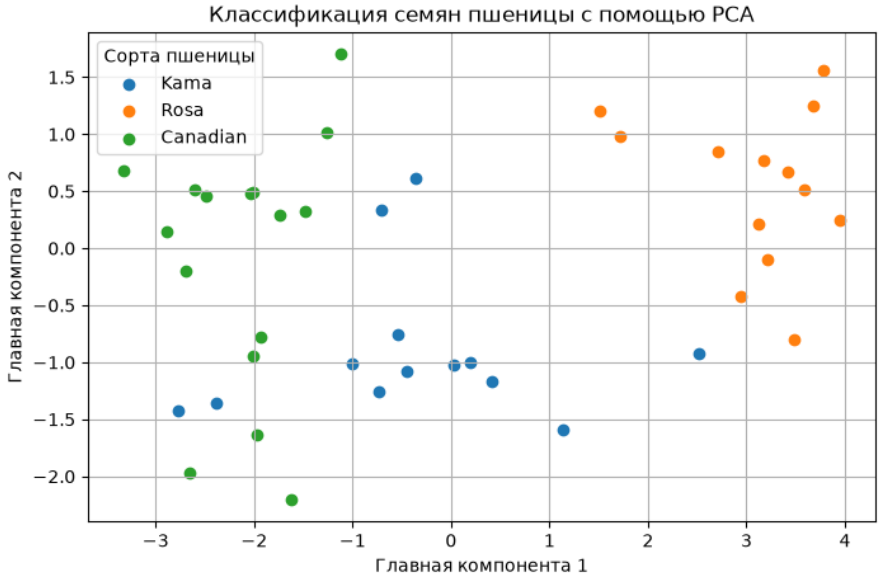
Лучшее значение k: 5
k-NN: Accuracy = 0.9048
Decision Tree: Accuracy = 0.9286
SVM: Accuracy = 0.9048

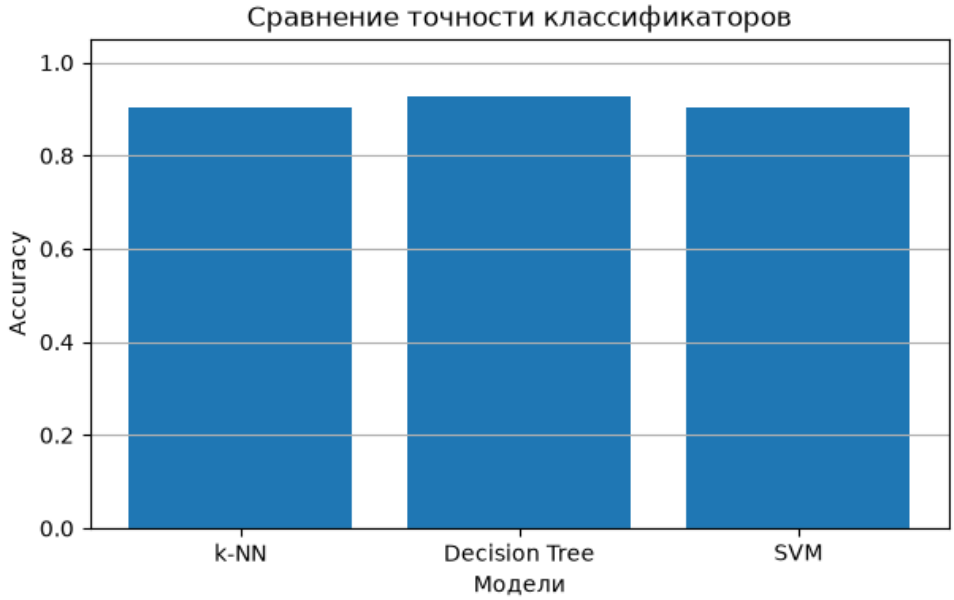
Лучшая модель: Decision Tree

ИТОГОВОЕ СРАВНЕНИЕ:
k-NN: 0.9048
Decision Tree: 0.9286
SVM: 0.9048

Лучшая модель: Decision Tree
Точность: 0.9286
```


Зависимость точности k-NN от значения k
Accuracy
0.905
0.900
0.895
0.890
0.885
0.880
1
3
5
7
9
Количество соседей (k)


Классификация семян пшеницы с помощью PCA
Сорта пшеницы
Kama
Rosa
Canadian
Главная компонента 2
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−2.0
−3
−2
−1
0
1
2
3
4
Главная компонента 1


Сравнение точности классификаторов
Accuracy
1.0
0.8
0.6
0.4
0.2
0.0
k-NN
Decision Tree
SVM
Модели

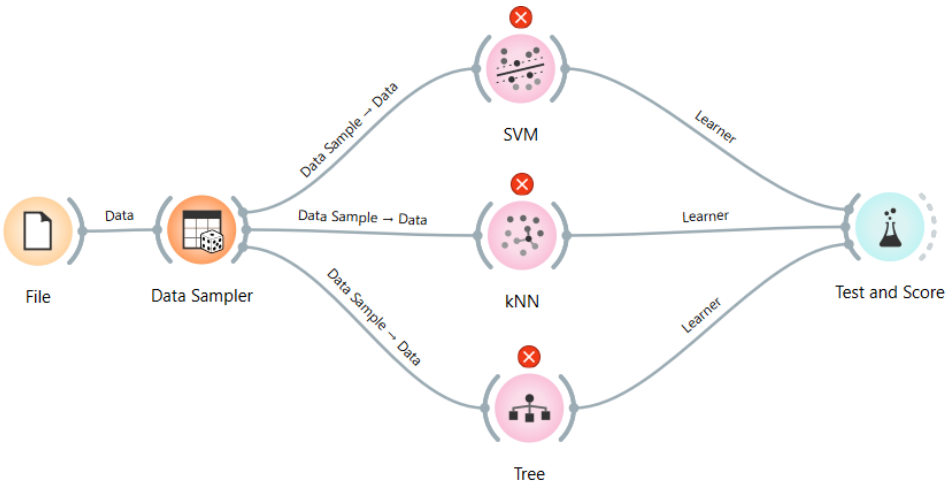


Рисунок 1 – Схема сравнения трех классификаторов (kNN, Tree, SVM)

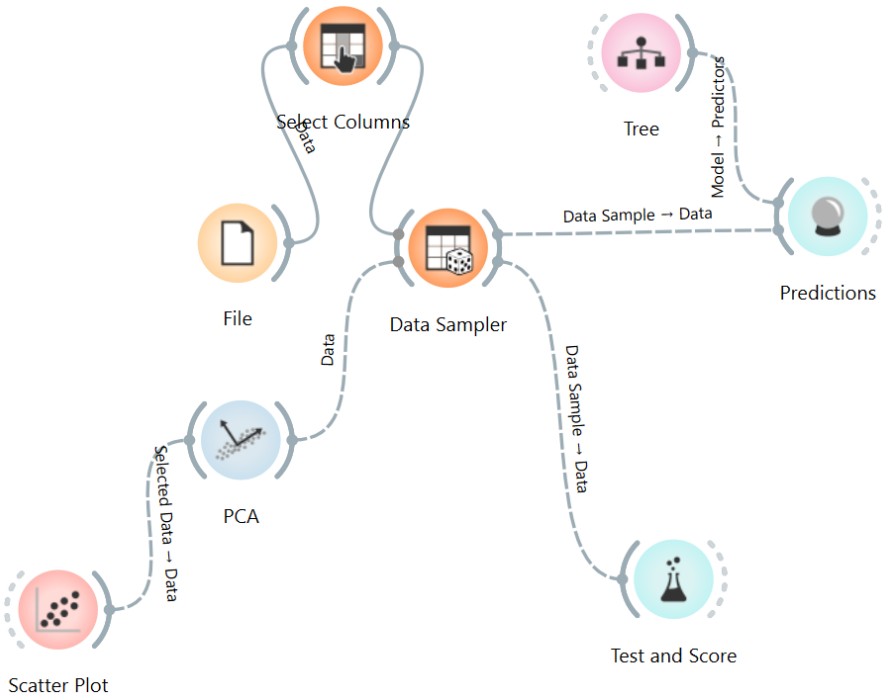


Рисунок 2 – Схема визуализации PCA

Вывод: На практике сравнила работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научилась подбирать гиперпараметры моделей и оценивать их влияние на результат.