МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ
Кафедра интеллектуальных информационных технологий

Отчёт по лабораторной работе №1

Специальность АС-67/24

Выполнил:
Тюрина Т. А.
Студент 3 курса
Группы АС-67
Проверил:
Крощенко А. А.
доц. ИИТ,

Брест 2026

Цель работы: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Ход работы

Вариант 9

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.

Код программы:

```
# Общее задание 1
# Загрузка датасета
df = pd.read_csv("Melbourne_housing.csv")

print("Датасет успешно загружен!")
print("Количество строк:", df.shape[0])
print("Количество столбцов:", df.shape[1])
```

Результат работы программы:

```
Датасет успешно загружен!
Количество строк: 34857
Количество столбцов: 22
/tmp/ipykernel_1206/1791526818.py:2: DtypeWarning: Columns (13) have mixed
types. Specify dtype option on import or set low_memory=False.
  df = pd.read_csv("Melbourne_housing.csv")
```

2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).

Код программы:

```
# Общее задание 2
# Исследовательский анализ данных

# 1. Типы данных
print("ТИПЫ ДАННЫХ")
print("-" * 40)
print(df.dtypes)

# 2. Количество пропущенных значений
print("\nПРОПУЩЕННЫЕ ЗНАЧЕНИЯ")
print("-" * 40)

missing_values = df.isnull().sum()
```

```
missing_values = missing_values[missing_values > 0]

print(missing_values)

# 3. Основные статистические показатели
print("\nОСНОВНЫЕ СТАТИСТИЧЕСКИЕ ПОКАЗАТЕЛИ")
print("-" * 40)

statistics = df.select_dtypes(include=np.number).agg(["mean", "median",
"std"])

display(statistics)
```

Результат работы программы:

```
ТИПЫ ДАННЫХ
----------------------------------------
Suburb            object
Address           object
Rooms              int64
Type              object
Method            object
SellerG           object
Date              object
Distance         float64
Postcode         float64
Bedroom          float64
Bathroom         float64
Car              float64
Landsize         float64
BuildingArea      object
YearBuilt        float64
CouncilArea       object
Latitude         float64
Longtitude       float64
Regionname        object
Propertycount    float64
ParkingArea       object
Price            float64
dtype: object

ПРОПУЩЕННЫЕ ЗНАЧЕНИЯ
----------------------------------------
Distance             1
Postcode             1
Bedroom           8217
Bathroom          8226
Car               8728
Landsize         11810
BuildingArea     21097
YearBuilt        19306
CouncilArea          3
Latitude          7976
Longtitude        7976
Propertycount        3
Price             7610
dtype: int64

ОСНОВНЫЕ СТАТИСТИЧЕСКИЕ ПОКАЗАТЕЛИ
----------------------------------------
```

	Rooms	Distance	Postcode	Bedroom	Bathroom	Car	Landsize	YearBuilt	Latitude	Longitude	Propertycount	Price
mean	3.031012	11.184929	3116.062859	3.084647	1.624798	1.728845	593.598993	1965.289885	-37.810634	145.001851	7572.888306	1.050173e+06
median	3.000000	10.300000	3103.000000	3.000000	2.000000	2.000000	521.000000	1970.000000	-37.807600	145.007800	6763.000000	8.700000e+05
std	0.969933	6.788892	109.023903	0.980690	0.724212	1.010771	3398.841946	37.328178	0.090279	0.120169	4428.090313	6.414671e+05

3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).

Выполнено в заданиях 1, 2.

4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.

5. Выполнить нормализацию или стандартизацию числовых признаков.

6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.

7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

Вариант 9

Выборка Melbourne Housing Market. Содержит данные о продажах домов в Мельбурне, включая цену, количество комнат, район и т.д.

Задачи:

1. Загрузите данные. Найдите столбец с наибольшим количеством пропущенных значений и удалите его.

Код программы:

```
# 1 задание
# Обработка пропущенных значений

# Находим столбец с наибольшим количеством пропусков
column_with_most_missing = df.isnull().sum().idxmax()
missing_count = df[column_with_most_missing].isnull().sum()

print("Столбец с наибольшим количеством пропусков:")
```

```
print(column_with_most_missing)
print("Количество пропусков:", missing_count)

# Удаляем этот столбец
df = df.drop(columns=[column_with_most_missing])

print("\nУдалён столбец:", column_with_most_missing)
print("Количество столбцов после удаления:", df.shape[1])
```

Результат работы программы:

```
Столбец с наибольшим количеством пропусков:
BuildingArea
Количество пропусков: 21097

Удалён столбец: BuildingArea
Количество столбцов после удаления: 21
```

2. Удалите все строки, где отсутствует значение цены (Price).

Код программы:

```
# 2 задание
# Удаляем строки без значения Price
rows_before = df.shape[0]

df = df.dropna(subset=["Price"])

rows_after = df.shape[0]

print("\nОбработка пропусков в Price:")
print("Строк до удаления:", rows_before)
print("Удалено строк:", rows_before - rows_after)
print("Строк после удаления:", rows_after)
```

Результат работы программы:

```
Обработка пропусков в Price:
Строк до удаления: 34857
Удалено строк: 7610
Строк после удаления: 27247
```

3. Постройте гистограмму распределения цен на недвижимость.

Код программы:

```
# 3 задание
# Гистограмма распределения цен на недвижимость

plt.figure(figsize=(10, 6))

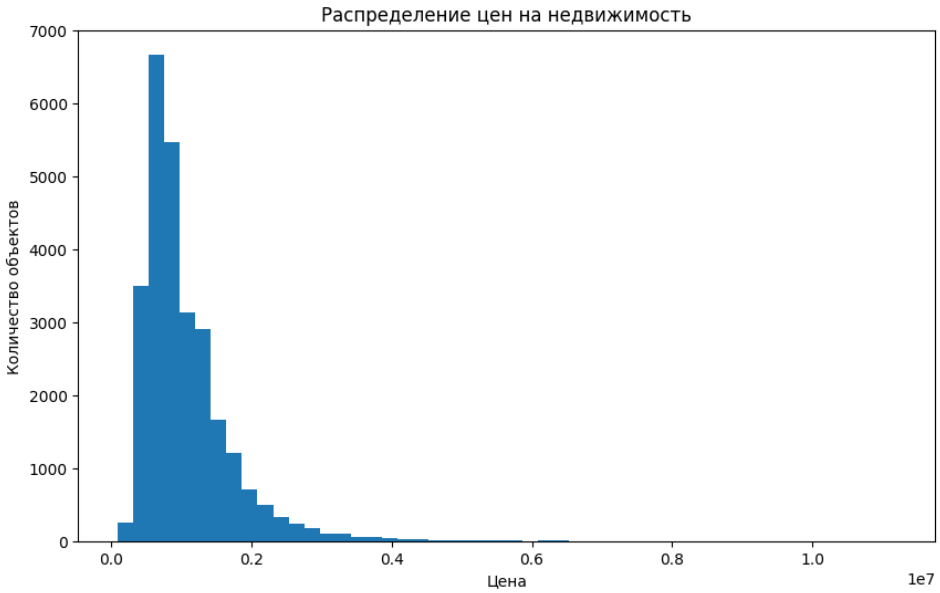
plt.hist(df["Price"], bins=50)

plt.title("Распределение цен на недвижимость")
```

```
plt.xlabel("Цена")
plt.ylabel("Количество объектов")

plt.show()
```

Результат работы программы:



4. Рассчитайте среднюю цену за дом для 5 самых популярных пригородов (Suburb).

Код программы:

```
# 4 задание
# Средняя цена дома для 5 самых популярных пригородов

# Находим 5 самых часто встречающихся пригородов
top_5_suburbs = df["Suburb"].value_counts().head(5)

print("5 самых популярных пригородов:")
display(top_5_suburbs)

# Рассчитываем среднюю цену для этих пригородов
average_price_top_5 = (
    df[df["Suburb"].isin(top_5_suburbs.index)]
    .groupby("Suburb")["Price"]
    .mean()
)

print("Средняя цена дома:")
display(average_price_top_5)
```

Результат работы программы:

```
5 самых популярных пригородов:
```

	count
Suburb	
Reservoir	727
Bentleigh East	493
Richmond	439
Preston	415
Brunswick	387

dtype: int64

```
Средняя цена дома:
```

	Price
Suburb	
Bentleigh East	1.131418e+06
Brunswick	9.779888e+05
Preston	8.778699e+05
Reservoir	6.911045e+05
Richmond	1.067585e+06

dtype: float64

5. Создайте новый признак PropertyAge на основе года постройки (YearBuilt).

Кода программы:

```
# Индивидуальное задание 5
# Создание нового признака PropertyAge

# Приводим YearBuilt к числовому типу
df["YearBuilt"] = pd.to_numeric(df["YearBuilt"], errors="coerce")

# Рассчитываем возраст недвижимости
current_year = 2026
df["PropertyAge"] = current_year - df["YearBuilt"]

print("Признак PropertyAge успешно создан.")
print("Количество значений PropertyAge:", df["PropertyAge"].notna().sum())
```

Результат выполнения программы:

```
Признак PropertyAge успешно создан.
Количество значений PropertyAge: 12084
```

6. Преобразуйте признак Type (тип недвижимости) в числовой формат с помощью One-Hot Encoding.

Код программы: