МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Кафедра «Интеллектуальные информационные технологии»

ЛАБОРАТОРНАЯ РАБОТА №1

по дисциплине «Основы машинного обучения»

Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Вариант 1

Выполнил:
студент 3 курса
группы АС-67
Швед М. С.
Проверил:
Крощенко А. А.

Брест 2026

Цель:

Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.

2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).

3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).

4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.

5. Выполнить нормализацию или стандартизацию числовых признаков.

6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.

7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Используемые инструменты: Python, Pandas, Matplotlib, NumPy, Google Colab / PyCharm

Вариант 1

Выборка Titanic. Содержит информацию о пассажирах лайнера, включая их возраст, пол, класс каюты и факт выживания.

Ход работы:

1. Загрузите данные и выведите первые 5 строк, а также общую информацию о столбцах (.info()).

```
   PassengerId  Survived  Pclass                     Name     Sex   Age  SibSp  Parch  \
0            1         0       3   Braund, Mr. Owen Harris    male  22.0      1      0
1            2         1       1  Cumings, Mrs. John Br...  female  38.0      1      0
2            3         1       3    Heikkinen, Miss. Laina  female  26.0      0      0
3            4         1       1  Futrelle, Mrs. Jacque...  female  35.0      1      0
4            5         0       3  Allen, Mr. William Henry    male  35.0      0      0

             Ticket     Fare Cabin Embarked
0         A/5 21171   7.2500   NaN        S
1          PC 17599  71.2833   C85        C
2  STON/O2. 3101282   7.9250   NaN        S
3            113803  53.1000  C123        S
4            373450   8.0500   NaN        S
<class 'pandas.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  891 non-null    int64
```

```
 1   Survived     891 non-null    int64
 2   Pclass       891 non-null    int64
 3   Name         891 non-null    str
 4   Sex          891 non-null    str
 5   Age          714 non-null    float64
 6   SibSp        891 non-null    int64
 7   Parch        891 non-null    int64
 8   Ticket       891 non-null    str
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    str
 11  Embarked     889 non-null    str
dtypes: float64(2), int64(5), str(5)
memory usage: 83.7 KB
```

Набор данных содержит 891 запись и 12 столбцов. Пропуски есть в столбцах Age (177), Cabin (687) и Embarked (2).

2. Найдите и визуализируйте количество выживших и погибших пассажиров с помощью столбчатой диаграммы.

```
Количество погибших (0) и выживших (1):
Survived
0    549
1    342
Name: count, dtype: int64
```

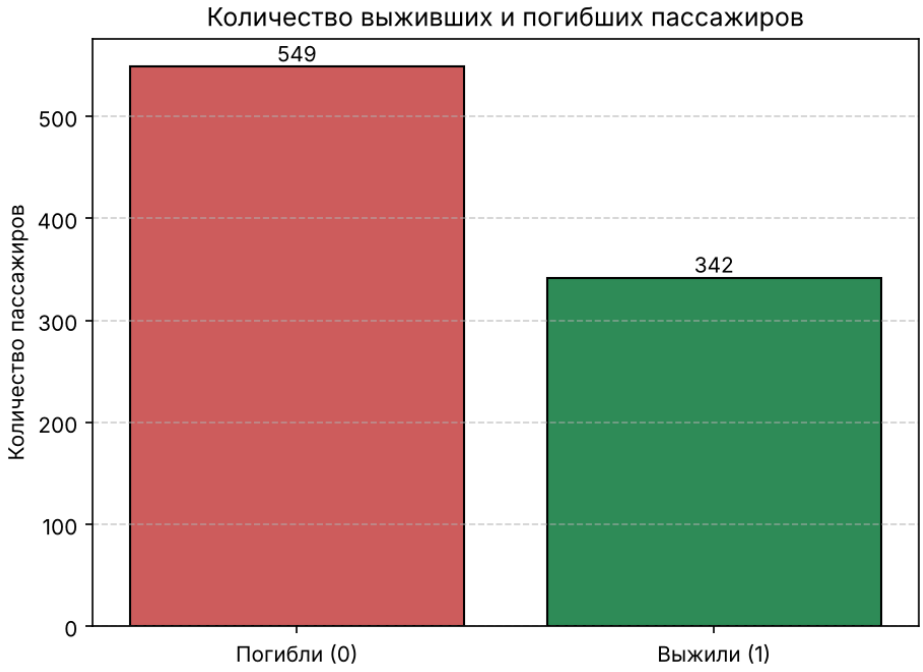


Рисунок 1 - Количество выживших и погибших пассажиров

Погибли 549 пассажиров (≈61,6 %), выжили 342 (≈38,4 %).

3. Обработайте пропуски в столбце Age, заполнив их медианным значением.

```
Пропуски в Age до обработки: 177
Медиана Age: 28.0
Пропуски в Age после обработки: 0
```

Медиана выбрана вместо среднего, так как она менее чувствительна к выбросам (пожилым пассажирам).

4. Преобразуйте категориальные признаки Sex и Embarked в числовые с помощью One-Hot Encoding.

```
Столбцы после One-Hot Encoding:
['PassengerId', 'Survived', 'Pclass', 'Name', 'Age', 'SibSp', 'Parch', 'Ticket', 'Fare', 'Cabin',
'Sex_female', 'Sex_male', 'Embarked_C', 'Embarked_Q', 'Embarked_S']
```

Вместо столбца Sex появились Sex_female и Sex_male, вместо Embarked - Embarked_C, Embarked_Q, Embarked_S (значения 0/1).

5. Постройте гистограмму распределения возрастов пассажиров.

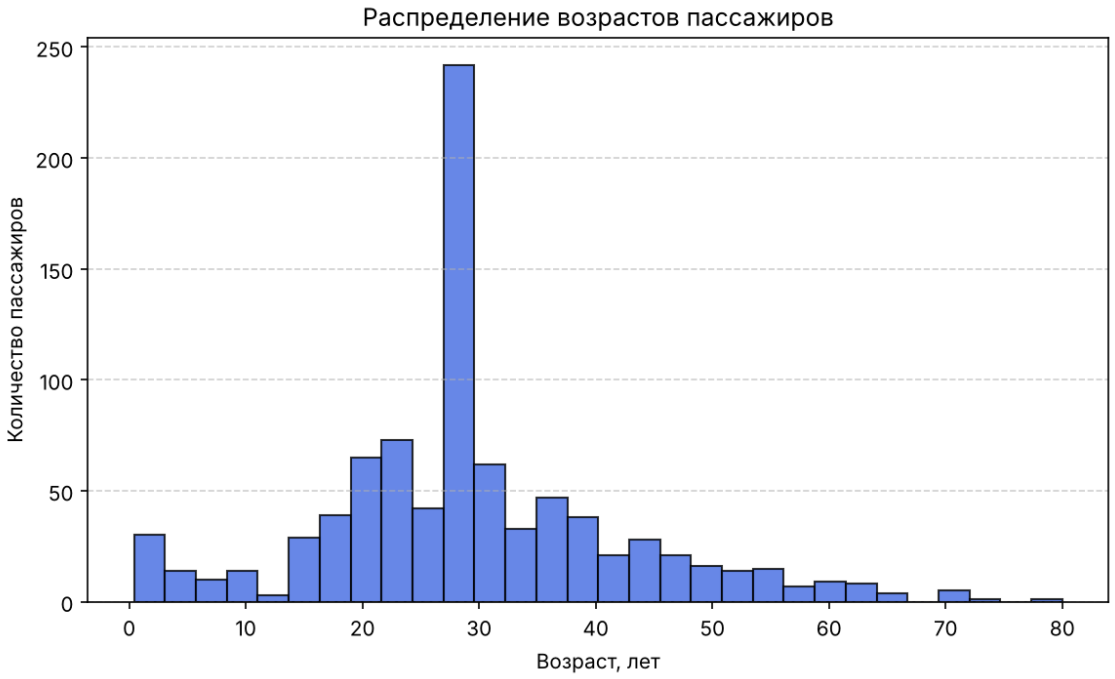


Рисунок 2 – Распределение возрастов пассажиров

Большинство пассажиров - в возрасте 20-40 лет. Выраженный пик в районе 28 лет вызван заполнением 177 пропусков медианой.

6. Создайте новый признак FamilySize путем сложения значений из столбцов SibSp и Parch.

```
Новый признак FamilySize:
   SibSp  Parch  FamilySize
0      1      0           1
1      1      0           1
2      0      0           0
3      1      0           1
4      0      0           0

Итоговый DataFrame:
   PassengerId  Survived  Pclass                     Name   Age  SibSp  Parch            Ticket  \
0            1         0       3   Braund, Mr. Owen Harris  22.0      1      0         A/5 21171
1            2         1       1  Cumings, Mrs. John Br...  38.0      1      0          PC 17599
2            3         1       3    Heikkinen, Miss. Laina  26.0      0      0  STON/O2. 3101282
3            4         1       1  Futrelle, Mrs. Jacque...  35.0      1      0            113803
4            5         0       3  Allen, Mr. William Henry  35.0      0      0            373450

      Fare Cabin  Sex_female  Sex_male  Embarked_C  Embarked_Q  Embarked_S  FamilySize
0   7.2500   NaN           0         1           0           0           1           1
1  71.2833   C85           1         0           1           0           0           1
2   7.9250   NaN           1         0           0           0           1           0
3  53.1000  C123           1         0           0           0           1           1
4   8.0500   NaN           0         1           0           0           1           0
```

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt


pd.set_option("display.max_columns", None)
pd.set_option("display.width", 100)
pd.set_option("display.max_colwidth", 25)


def main():
    # 1. Загрузка данных, первые 5 строк и информация о столбцах
    df = pd.read_csv("Titanic-Dataset.csv")

    print(df.head())
    df.info()

    # 2. Количество выживших и погибших + столбчатая диаграмма
    survived_counts = df["Survived"].value_counts().sort_index()
    print("\nКоличество погибших (0) и выживших (1):")
    print(survived_counts)

    plt.figure(figsize=(7, 5))
    bars = plt.bar(
        ["Погибли (0)", "Выжили (1)"],
        survived_counts.values,
        color=["indianred", "seagreen"],
        edgecolor="k"
    )
    plt.bar_label(bars)
    plt.title("Количество выживших и погибших пассажиров")
    plt.ylabel("Количество пассажиров")
    plt.grid(axis="y", linestyle="--", alpha=0.6)
    plt.show()

    # 3. Заполнение пропусков в Age медианой
    print(f"\nПропуски в Age до обработки: {df['Age'].isnull().sum()}")
    median_age = df["Age"].median()
    df["Age"] = df["Age"].fillna(median_age)
    print(f"Медиана Age: {median_age}")
    print(f"Пропуски в Age после обработки: {df['Age'].isnull().sum()}")

    # 4. One-Hot Encoding для Sex и Embarked
    df = pd.get_dummies(df, columns=["Sex", "Embarked"], dtype=int)
    print("\nСтолбцы после One-Hot Encoding:")
    print(df.columns.tolist())

    # 5. Гистограмма распределения возрастов
    plt.figure(figsize=(9, 5))
    plt.hist(df["Age"], bins=30, color="royalblue", edgecolor="k", alpha=0.8)
    plt.title("Распределение возрастов пассажиров")
    plt.xlabel("Возраст, лет")
    plt.ylabel("Количество пассажиров")
    plt.grid(axis="y", linestyle="--", alpha=0.6)
    plt.show()

    # 6. Новый признак FamilySize
    df["FamilySize"] = df["SibSp"] + df["Parch"]
    print("\nНовый признак FamilySize:")
    print(df[["SibSp", "Parch", "FamilySize"]].head())

    print("\nИтоговый DataFrame:")
    print(df.head())


if __name__ == "__main__":
    main()
```

Вывод:

В ходе лабораторной работы я познакомился с библиотеками Pandas и Matplotlib: загрузил и исследовал набор данных Titanic, заполнил пропуски в возрасте медианой, преобразовал категориальные признаки Sex и Embarked методом One-Hot Encoding, построил столбчатую диаграмму и гистограмму, а также создал новый признак FamilySize.