МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность АС-67

Выполнил
И. А. Якимович,
студент группы АС-67

Проверил
А. А. Крощенко,
ст. преп. кафедры ИИТ,
«___> _____2026 г.

Брест 2026

Цель работы: получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных,такие как очистка, нормализация и работа с различными типами признаков.

Вариант 1

Выборка Titanic. Содержит информацию о пассажирах лайнера, включая их возраст, пол, класс каюты и факт выживания.

Задачи:

1. Загрузите данные и выведите первые 5 строк, а также общую информацию о столбцах (.info()).

2. Найдите и визуализируйте количество выживших и погибших пассажиров с помощью столбчатой диаграммы.

3. Обработайте пропуски в столбце Age, заполнив их медианным значением.

4. Преобразуйте категориальные признаки Sex и Embarked в числовые с помощью One-Hot Encoding.

5. Постройте гистограмму распределения возрастов пассажиров.

6. Создайте новый признак FamilySize путем сложения значений из столбцов SibSp и Parch.

Выполнение:

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path

pd.set_option("display.max_columns", None)
pd.set_option("display.width", 1500)

file_path = Path(__file__).resolve().parent / "Titanic-Dataset.csv"
df = pd.read_csv(file_path)

print("1. Первые 5 строк:")
print(df.head().to_string(index=False))

print("\nИнформация о столбцах:")
df.info()

print("\nКоличество пропусков:")
print(df.isnull().sum())

numeric_columns = ["Age", "SibSp", "Parch", "Fare"]

statistics = df[numeric_columns].agg(["mean", "median", "std"])
statistics.index = ["Среднее", "Медиана", "Стандартное отклонение"]

print("\nСтатистические показатели:")
print(statistics.round(2))

survival_counts = df["Survived"].value_counts().reindex([0, 1], fill_value=0)

print("\n2. Количество погибших и выживших:")
print(f"Погибли: {survival_counts[0]}")
```

```
print(f"Выжили: {survival_counts[1]}")

plt.figure(figsize=(7, 5))
bars = plt.bar(
    ["Погибли", "Выжили"],
    survival_counts.values,
    color=["tomato", "mediumseagreen"]
)
plt.bar_label(bars)
plt.title("Количество погибших и выживших пассажиров")
plt.ylabel("Количество пассажиров")
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()

age_median = df["Age"].median()
df["Age"] = df["Age"].fillna(age_median)

print("\n3. Обработка пропусков в Age:")
print(f"Медианный возраст: {age_median}")
print(f"Осталось пропусков: {df['Age'].isnull().sum()}")

df["Embarked"] = df["Embarked"].fillna(df["Embarked"].mode()[0])

df_encoded = pd.get_dummies(
    df,
    columns=["Sex", "Embarked"],
    dtype=int
)

encoded_columns = [
    column for column in df_encoded.columns
    if column.startswith(("Sex_", "Embarked_"))
]

print("\n4. Результат One-Hot Encoding:")
print(df_encoded[encoded_columns].head().to_string(index=False))

plt.figure(figsize=(8, 5))
plt.hist(df["Age"], bins=20, color="skyblue", edgecolor="black")
plt.title("Распределение возрастов пассажиров")
plt.xlabel("Возраст, лет")
plt.ylabel("Количество пассажиров")
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()

df["FamilySize"] = df["SibSp"] + df["Parch"]
df_encoded["FamilySize"] = df["FamilySize"]

print("\n5. Новый признак FamilySize:")
print(df[["SibSp", "Parch", "FamilySize"]].head(10).to_string(index=False))

normalization_columns = ["Age", "SibSp", "Parch", "Fare", "FamilySize"]
df_normalized = df_encoded.copy()

for column in normalization_columns:
    minimum = df_normalized[column].min()
    maximum = df_normalized[column].max()

    if maximum != minimum:
        df_normalized[column] = (
            (df_normalized[column] - minimum) / (maximum - minimum)
        )
    else:
        df_normalized[column] = 0.0
```

```
print("\nНормализация числовых признаков:")
print(df_normalized[normalization_columns].head().round(3).to_string(index=Fa
lse))

print("\nДоля выживших в зависимости от пола, %:")
print((df.groupby("Sex")["Survived"].mean() * 100).round(2))

print("\nДоля выживших в зависимости от класса, %:")
print((df.groupby("Pclass")["Survived"].mean() * 100).round(2))

plt.show()
```

Результат программы:

1. Первые 5 строк:

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.0	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

Информация о столбцах:

<class 'pandas.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):

#	Column	Non-Null Count	Dtype
0	PassengerId	891 non-null	int64
1	Survived	891 non-null	int64
2	Pclass	891 non-null	int64
3	Name	891 non-null	str
4	Sex	891 non-null	str
5	Age	714 non-null	float64
6	SibSp	891 non-null	int64
7	Parch	891 non-null	int64
8	Ticket	891 non-null	str
9	Fare	891 non-null	float64
10	Cabin	204 non-null	str
11	Embarked	889 non-null	str

dtypes: float64(2), int64(5), str(5)
memory usage: 83.7 KB

Количество пропусков:

PassengerId	0
Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Cabin	687
Embarked	2

dtype: int64

Статистические показатели:

	Age	SibSp	Parch	Fare
Среднее	29.70	0.52	0.38	32.20
Медиана	28.00	0.00	0.00	14.45
Стандартное отклонение	14.53	1.10	0.81	49.69

2. Количество погибших и выживших:
Погибли: 549
Выжили: 342

3. Обработка пропусков в Age:
Медианный возраст: 28.0
Осталось пропусков: 0

4. Результат One-Hot Encoding:

Sex_female	Sex_male	Embarked_C	Embarked_Q	Embarked_S
0	1	0	0	1
1	0	1	0	0
1	0	0	0	1
1	0	0	0	1
0	1	0	0	1

5. Новый признак FamilySize:

SibSp	Parch	FamilySize
1	0	1
1	0	1
0	0	0
1	0	1
0	0	0
0	0	0
0	0	0
3	1	4
0	2	2
1	0	1

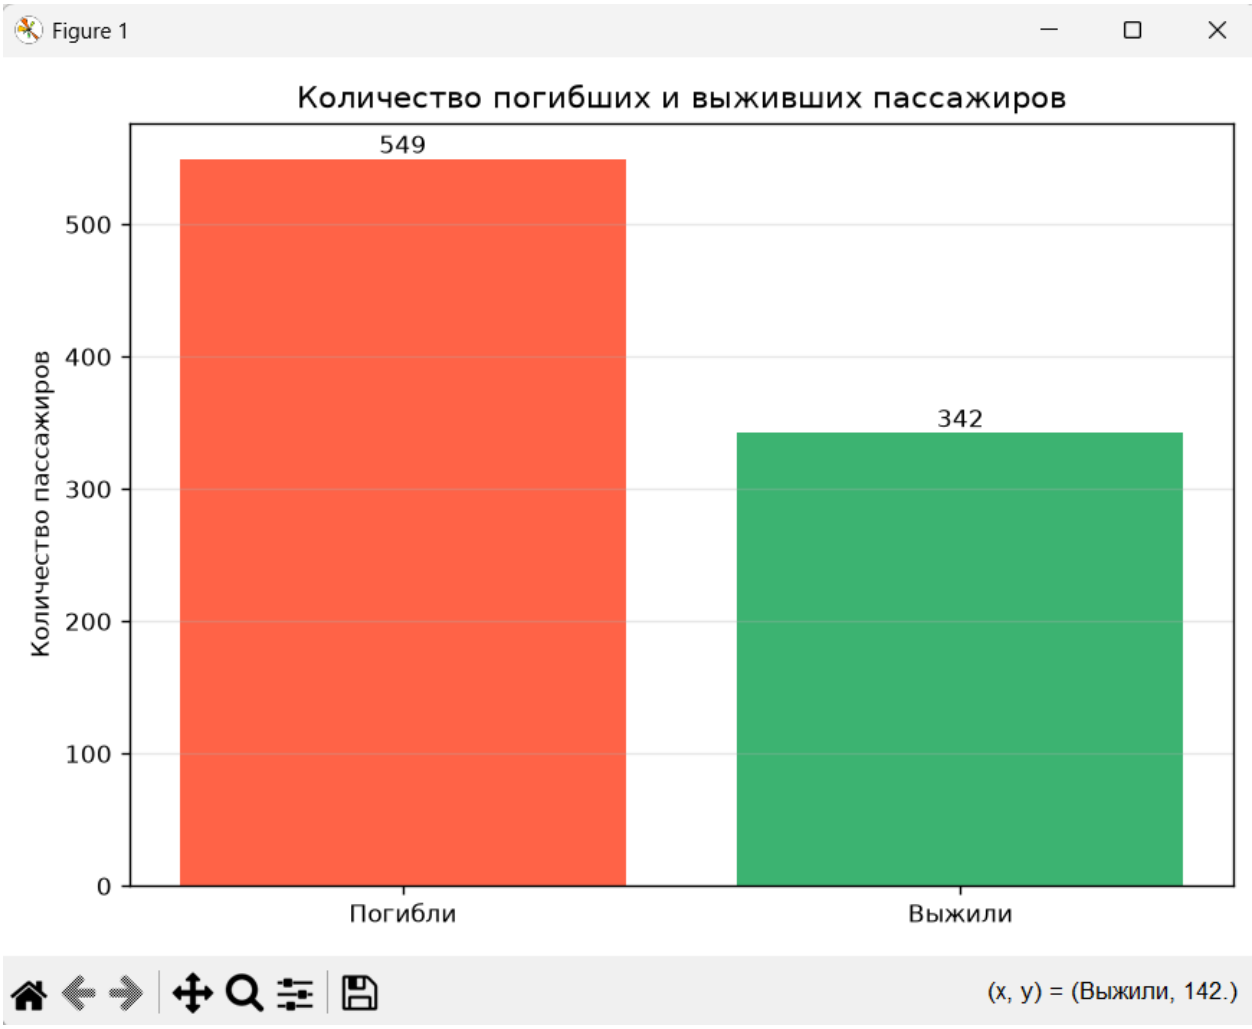
Нормализация числовых признаков:

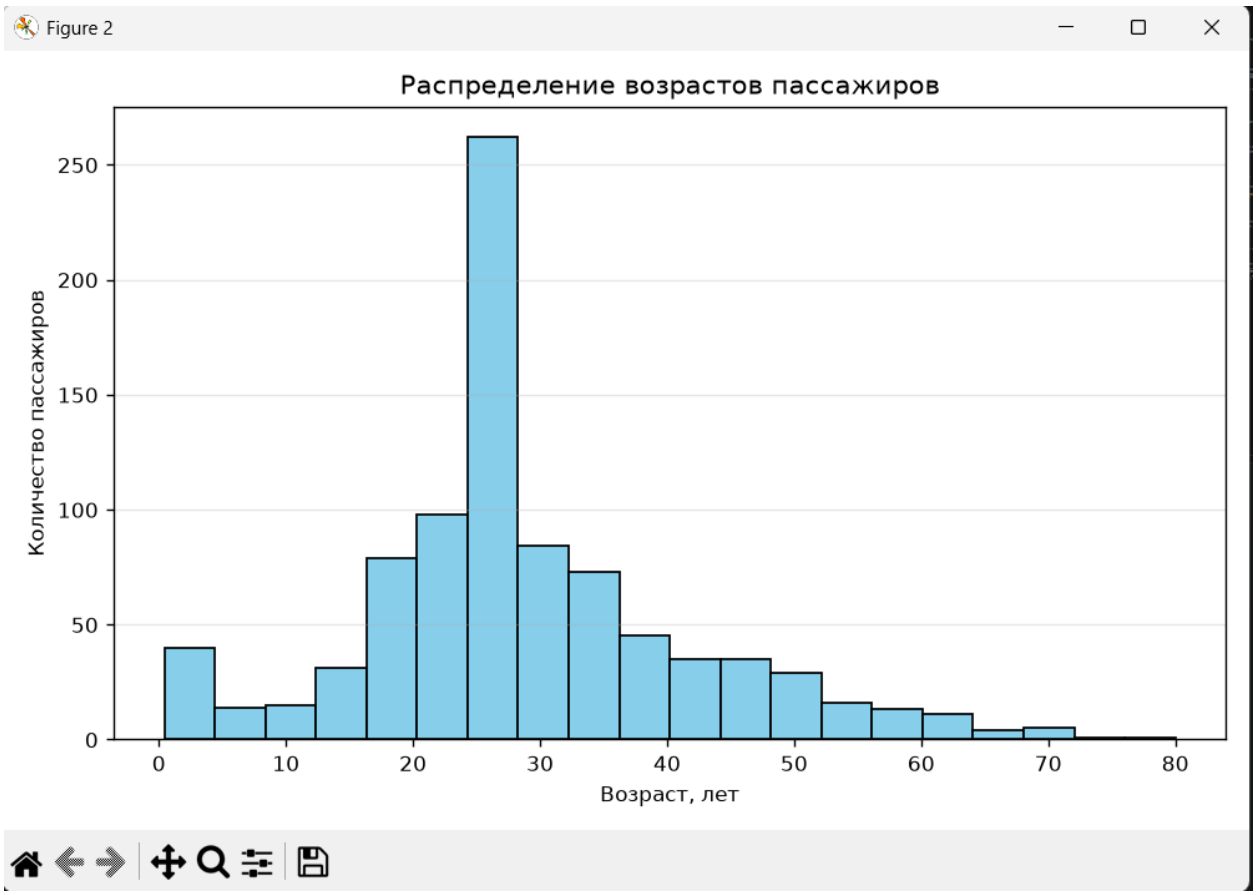
Age	SibSp	Parch	Fare	FamilySize
0.271	0.125	0.0	0.014	0.1
0.472	0.125	0.0	0.139	0.1
0.321	0.000	0.0	0.015	0.0
0.435	0.125	0.0	0.104	0.1
0.435	0.000	0.0	0.016	0.0

Доля выживших в зависимости от пола, %:
Sex
female 74.20
male 18.89
Name: Survived, dtype: float64

Доля выживших в зависимости от класса, %:
Pclass

1 62.96
2 47.28
3 24.24
Name: Survived, dtype: float64




Figure 2
Распределение возрастов пассажиров
Количество пассажиров
0
50
100
150
200
250
0
10
20
30
40
50
60
70
80
Возраст, лет